

# **ESTADÍSTICA BAYESIANA**

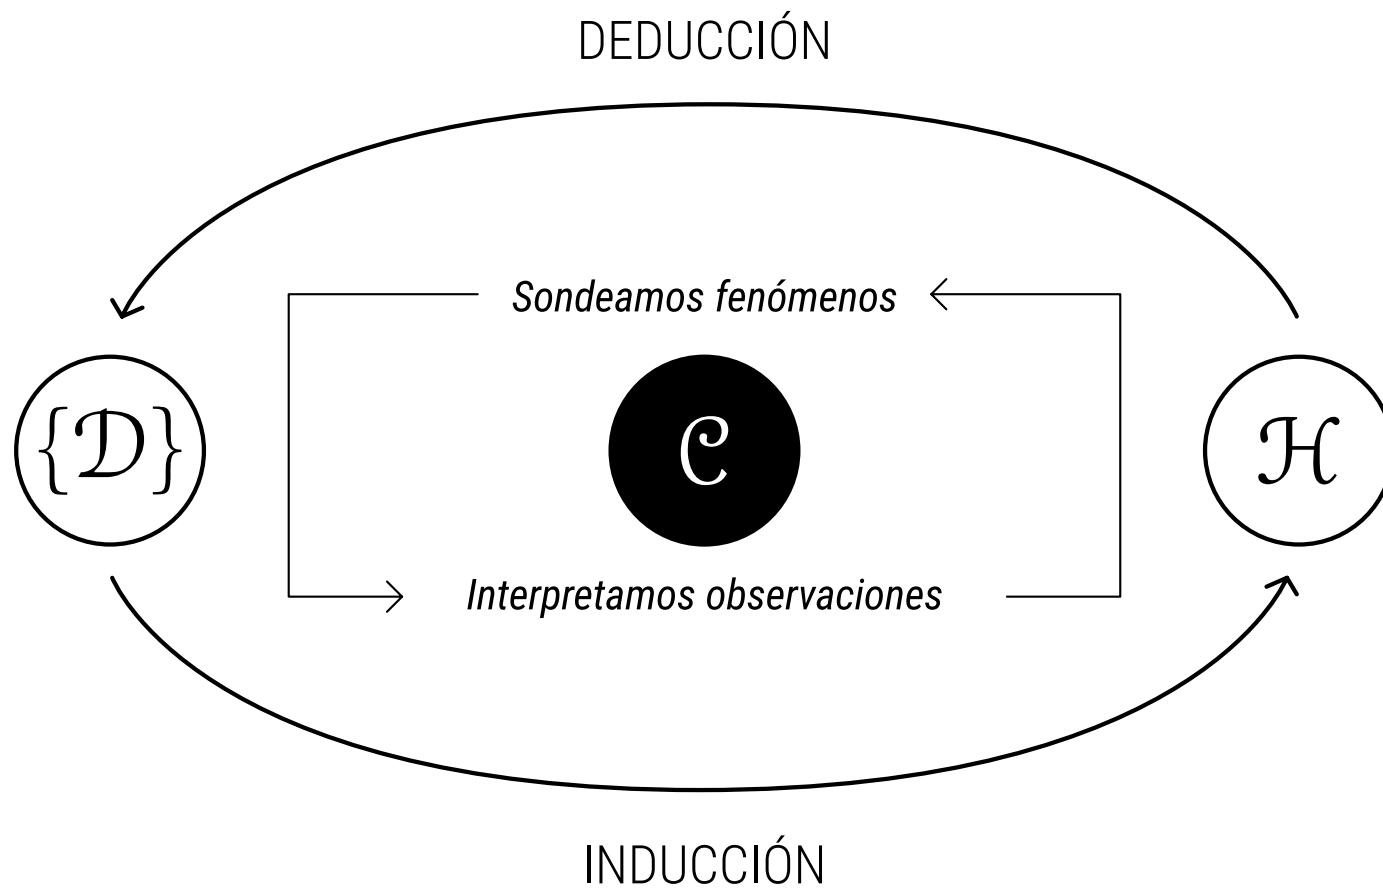
## **UN CONJUNTO DE PROCEDIMIENTOS ÚTILES**

Por  
Alfredo J. Mejía

# ESTRUCTURA

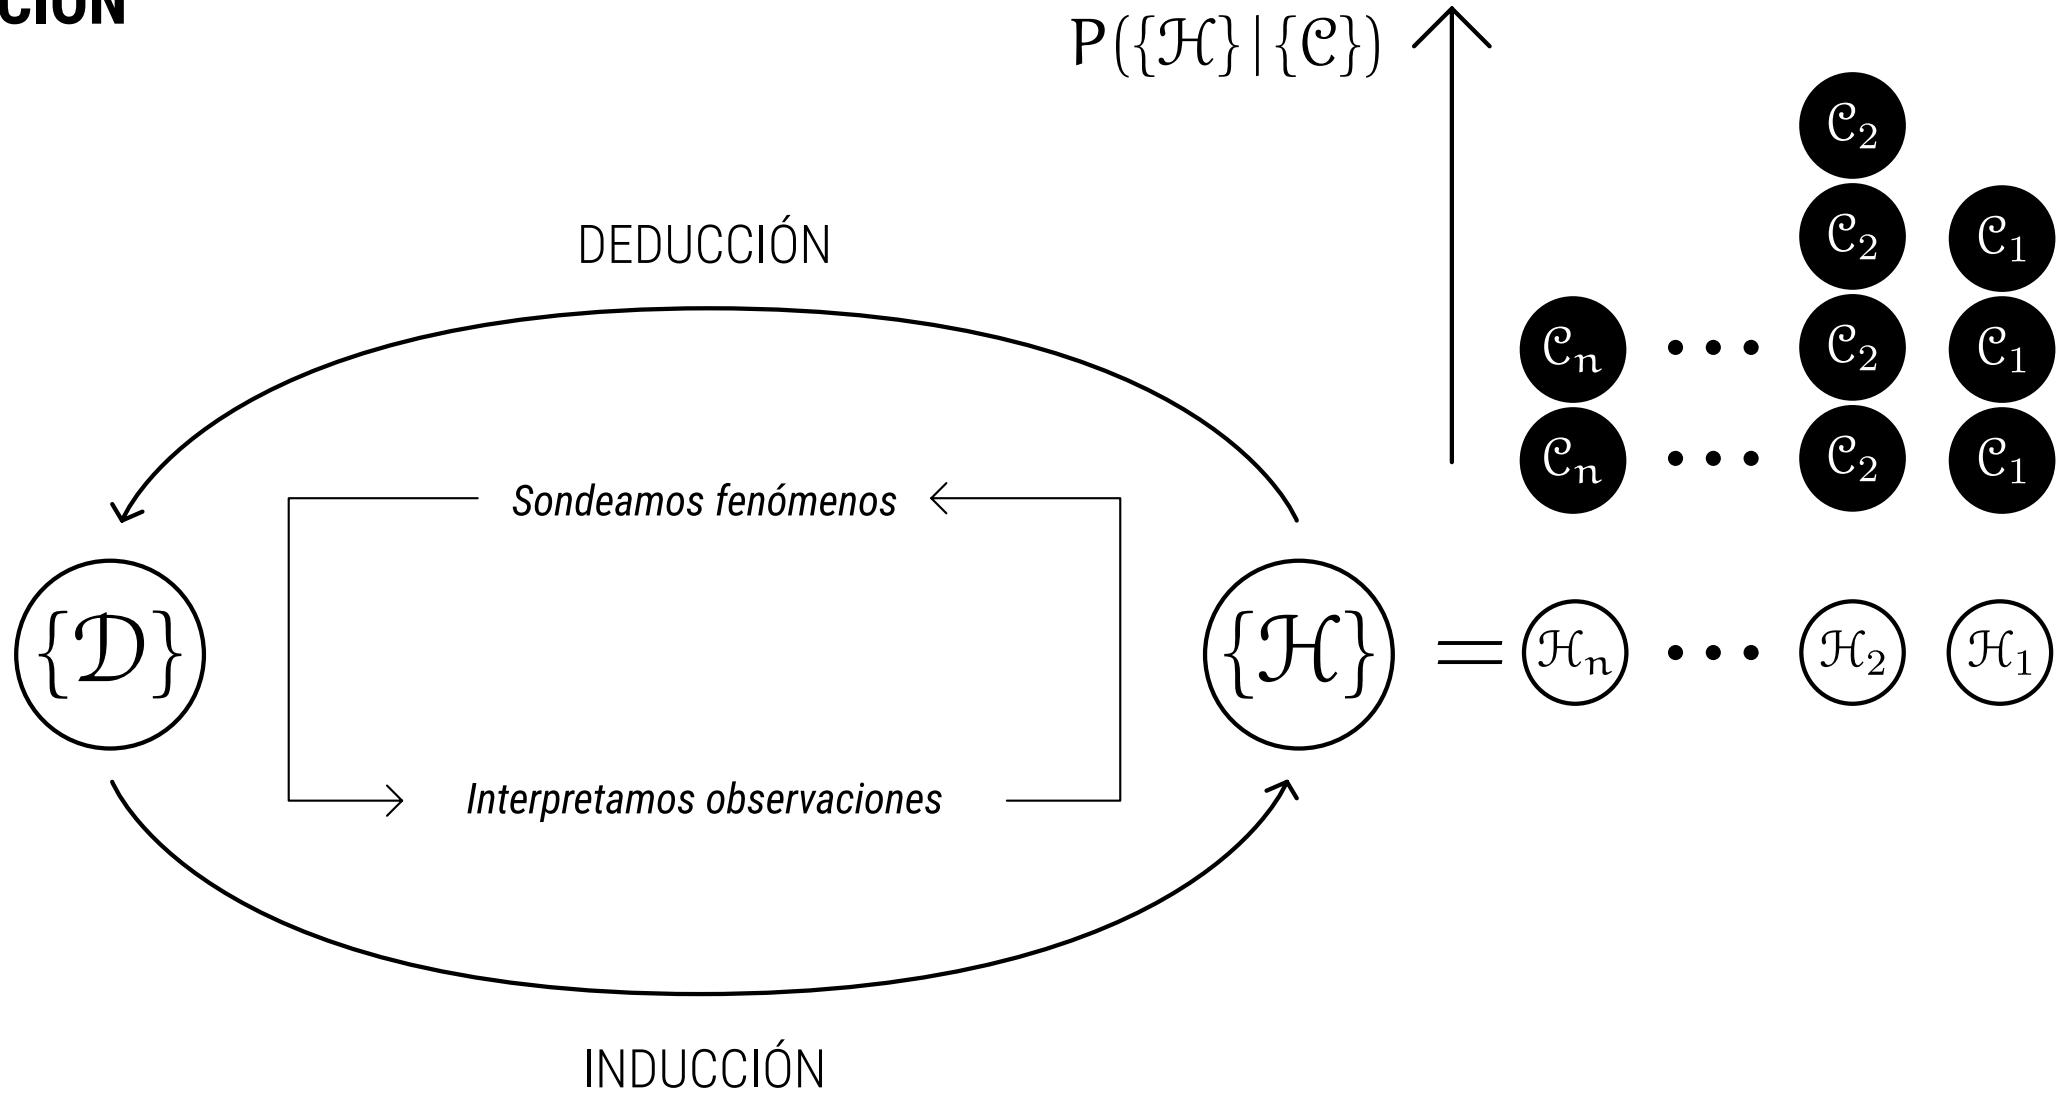
- Motivación
- Probabilidades 101
- Teorema de Bayes
- Regresión Lineal
  - ▶ Máxima Verosimilitud
  - ▶ Marginalización
  - ▶ El rol de la Distribución Previa
  - ▶ ¿Cómo asignar la Distribución Previa?
- Resumen

# MOTIVACIÓN



(Sivia+2006)

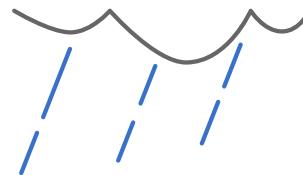
# MOTIVACIÓN



(Sivia+2006)

# PROBABILIDADES 101

PROBABILIDAD: grado de certidumbre sobre la ocurrencia de un evento.



L

$$P(L | \mathcal{C}) = 0,76$$



S =  $\bar{L}$

$$P(S | \mathcal{C}) = 0,24$$

REGLAS DE COX:

$$\sum_i P(\mathcal{H}_i | \mathcal{C}) = 1$$

$$P(S | \mathcal{C}) = 1 - P(L | \mathcal{C})$$

La certidumbre de ocurrencia de un evento define también su [incertidumbre](#).

$$P(\mathcal{H}_A, \mathcal{H}_B | \mathcal{C}) = P(\mathcal{H}_A | \mathcal{H}_B, \mathcal{C}) \times P(\mathcal{H}_B | \mathcal{C})$$

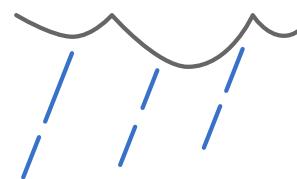
# PROBABILIDADES 101

PROBABILIDAD: grado de certidumbre sobre la ocurrencia de un evento.



N

$$P(N | \mathcal{C}) = 0,63$$



L

$$P(L | N, \mathcal{C}) = 0,81$$

REGLAS DE COX:

$$\sum_i P(\mathcal{H}_i | \mathcal{C}) = 1$$

$$P(L, \bar{N} | \mathcal{C}) \leq [1 - P(L | N, \mathcal{C})] \times P(\bar{N} | \mathcal{C})$$

$$P(L, \bar{N} | \mathcal{C}) \leq 0,07$$

$$P(\mathcal{H}_A, \mathcal{H}_B | \mathcal{C}) = P(\mathcal{H}_A | \mathcal{H}_B, \mathcal{C}) \times P(\mathcal{H}_B | \mathcal{C})$$

# TEOREMA DE BAYES

Estado de conocimiento  
sobre la hipótesis  
posterior a la observación

Probabilidad de la observación  
dada la hipótesis

Estado de conocimiento  
sobre la hipótesis  
previo a la observación

$$P(\mathcal{H} | \mathcal{D}, \mathcal{C}) = \frac{P(\mathcal{D} | \mathcal{H}, \mathcal{C}) \times P(\mathcal{H} | \mathcal{C})}{P(\mathcal{D} | \mathcal{C})}$$

Evidencia o distribución  
posterior marginalizada

# TEOREMA DE BAYES

Estado de conocimiento  
sobre la hipótesis  
posterior a la observación

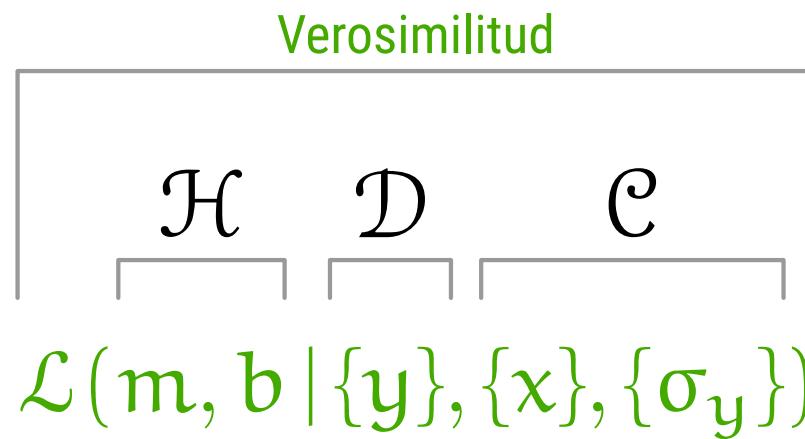
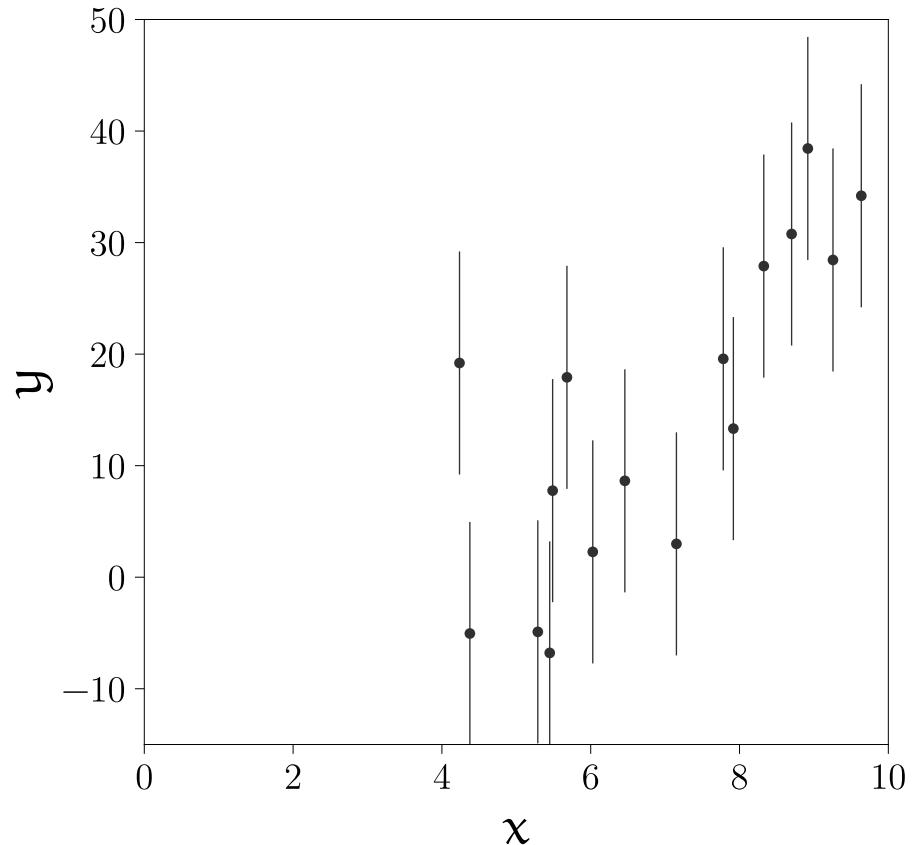
Verosimilitud de la hipótesis  
frente a la observación

Estado de conocimiento  
sobre la hipótesis  
previo a la observación

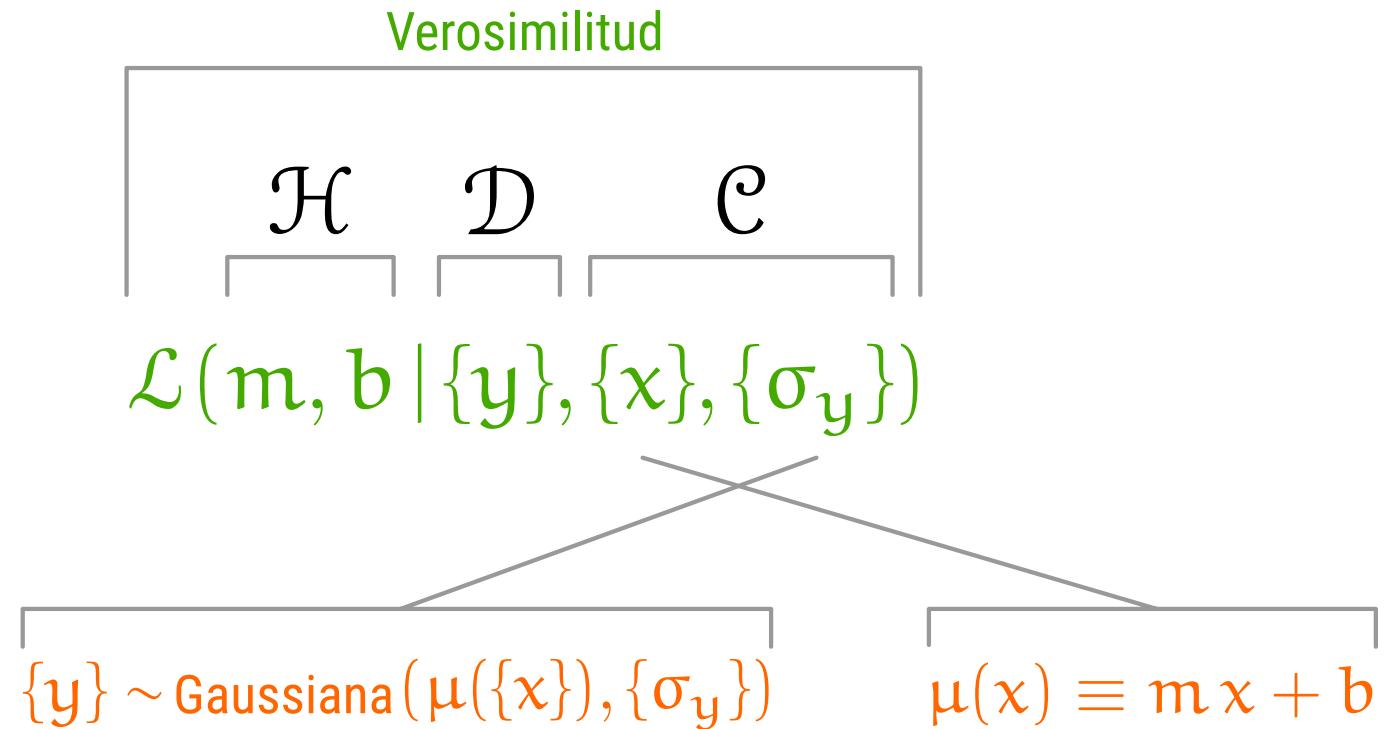
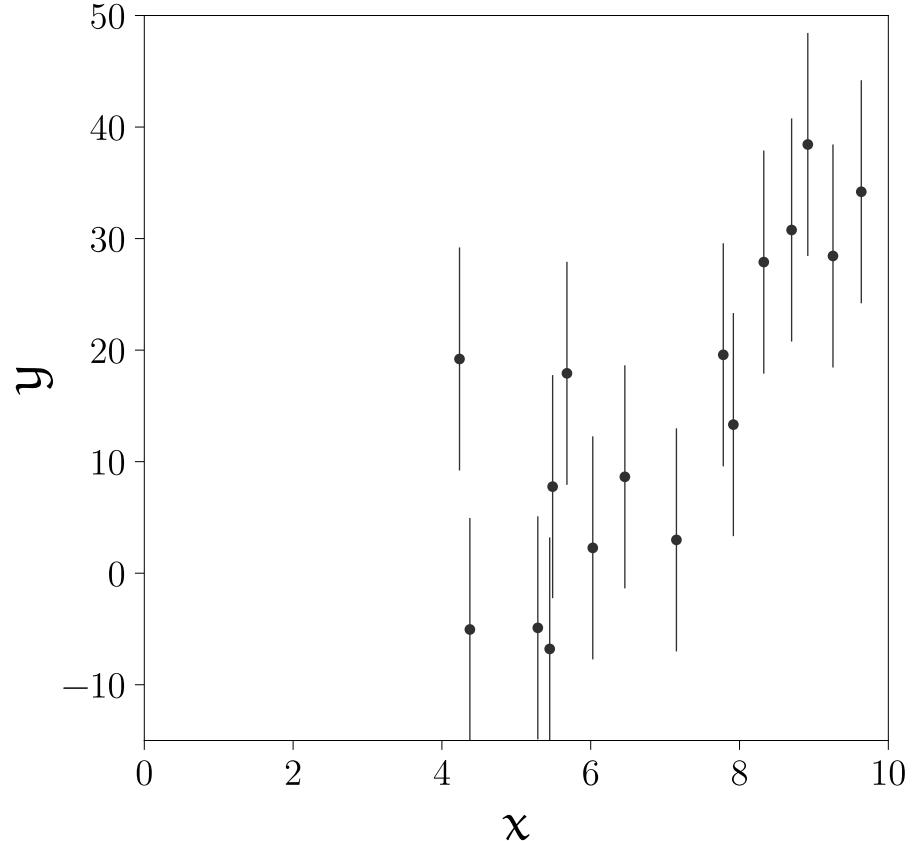
$$P(\mathcal{H} | \mathcal{D}, \mathcal{C}) = \frac{\mathcal{L}(\mathcal{H} | \mathcal{D}, \mathcal{C}) \times P(\mathcal{H} | \mathcal{C})}{P(\mathcal{D} | \mathcal{C})}$$

Evidencia o distribución  
posterior marginalizada

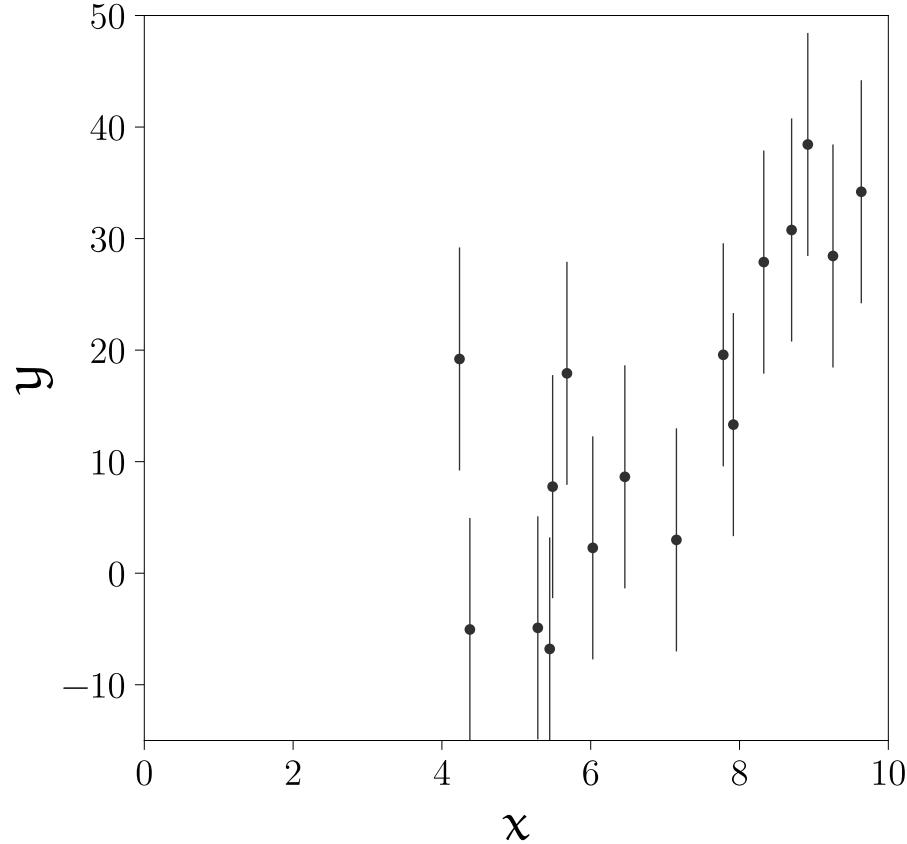
# VEROSIMILITUD – REGRESIÓN LINEAL



# VEROSIMILITUD – REGRESIÓN LINEAL



# VEROSIMILITUD – REGRESIÓN LINEAL



Verosimilitud

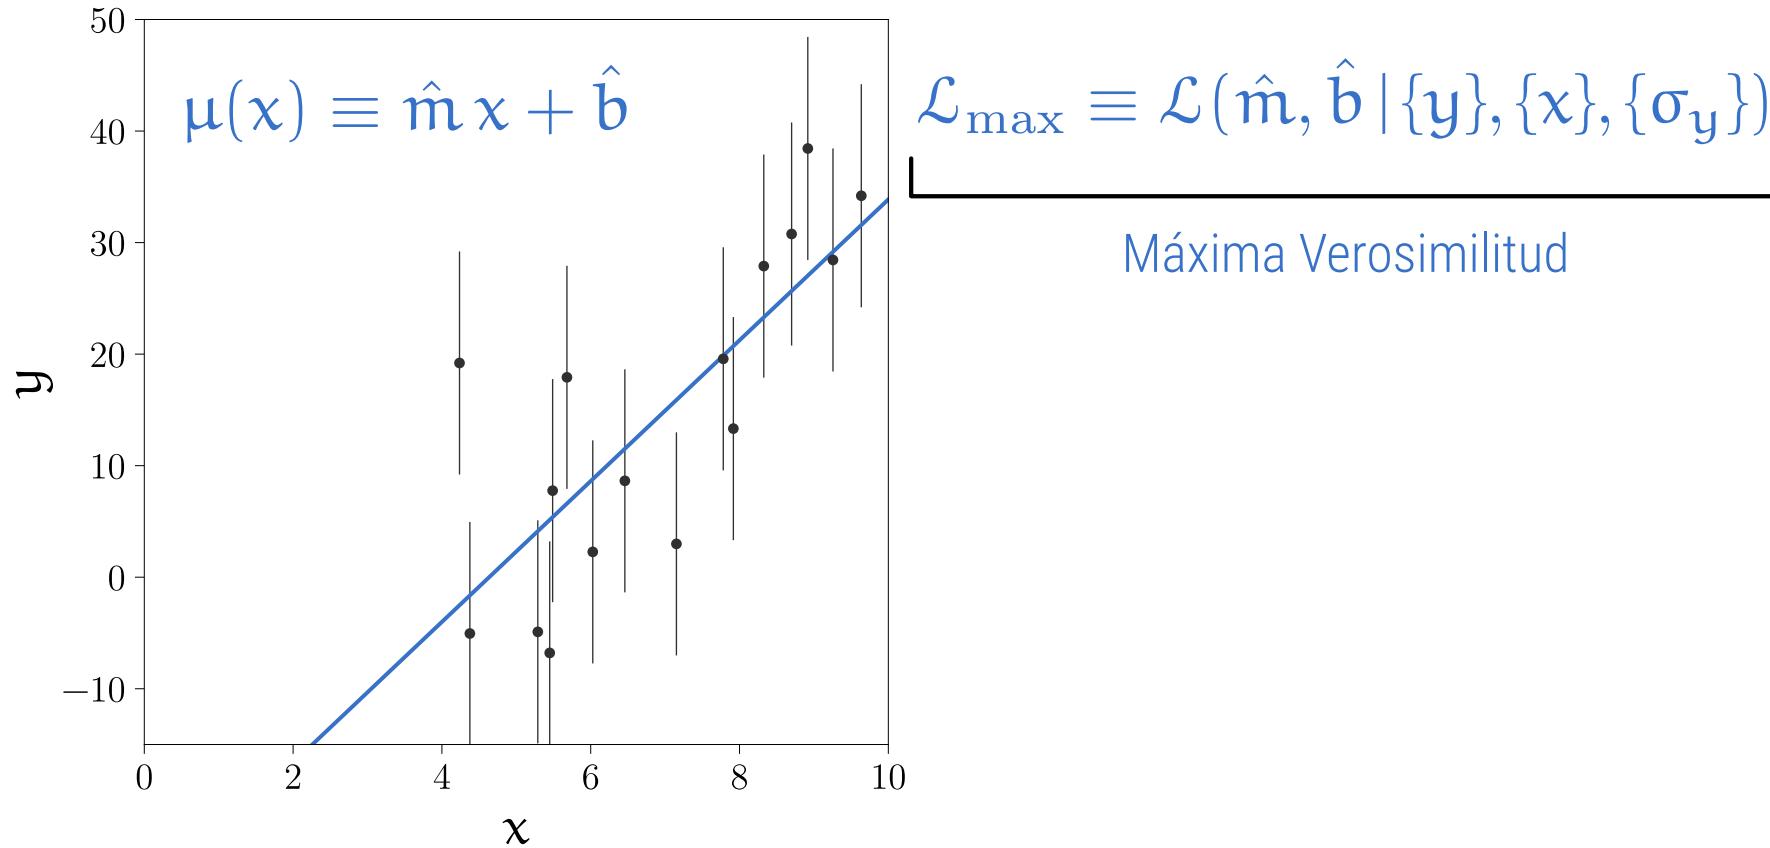
$$\mathcal{L}(m, b | \{y\}, \{x\}, \{\sigma_y\})$$

$$\{y\} \sim \text{Gaussiana}(\mu(\{x\}), \{\sigma_y\})$$

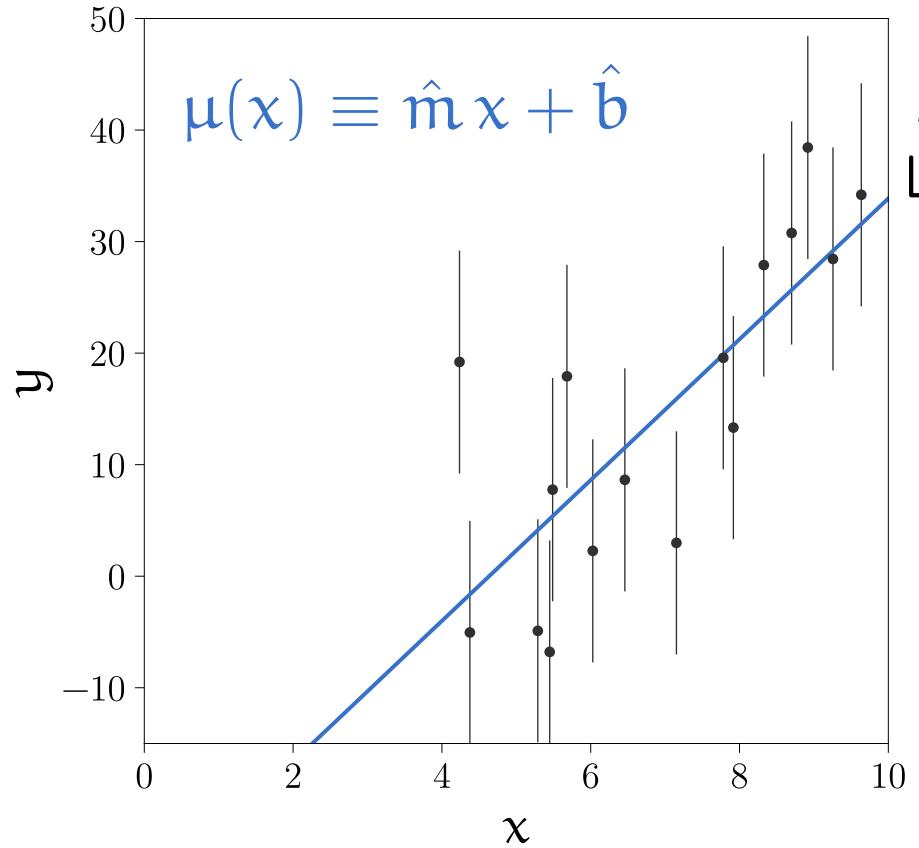
$$\mu(x) \equiv mx + b$$

$$\mathcal{L}(m, b | \{y\}, \{x\}, \{\sigma_y\}) \propto \prod_i \exp \left[ -\frac{(\mu(m, b; x_i) - y_i)^2}{2\sigma_{y_i}^2} \right]$$

# VEROSIMILITUD – REGRESIÓN LINEAL

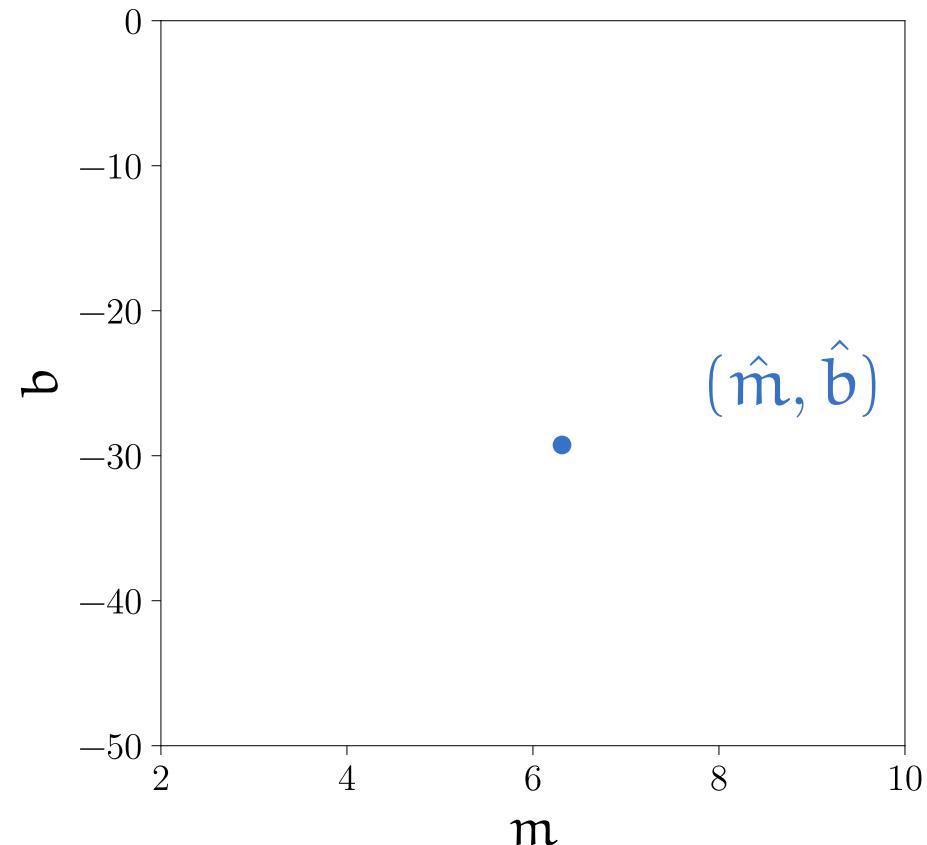


# VEROSIMILITUD – REGRESIÓN LINEAL



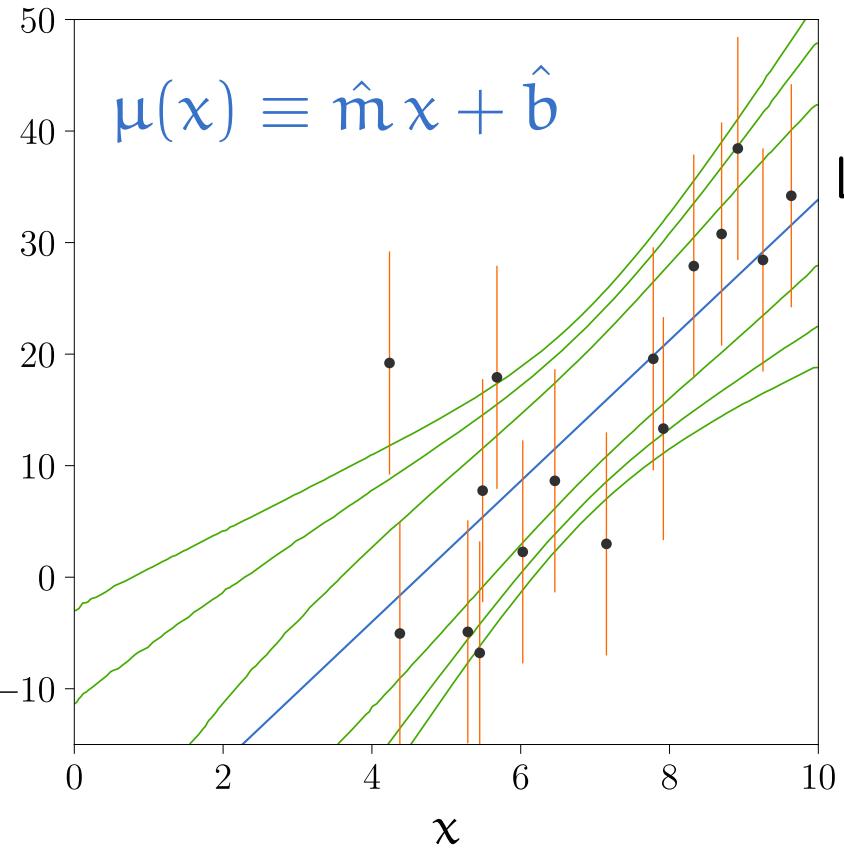
$$\mathcal{L}_{\max} \equiv \mathcal{L}(\hat{m}, \hat{b} | \{y\}, \{x\}, \{\sigma_y\})$$

Máxima Verosimilitud



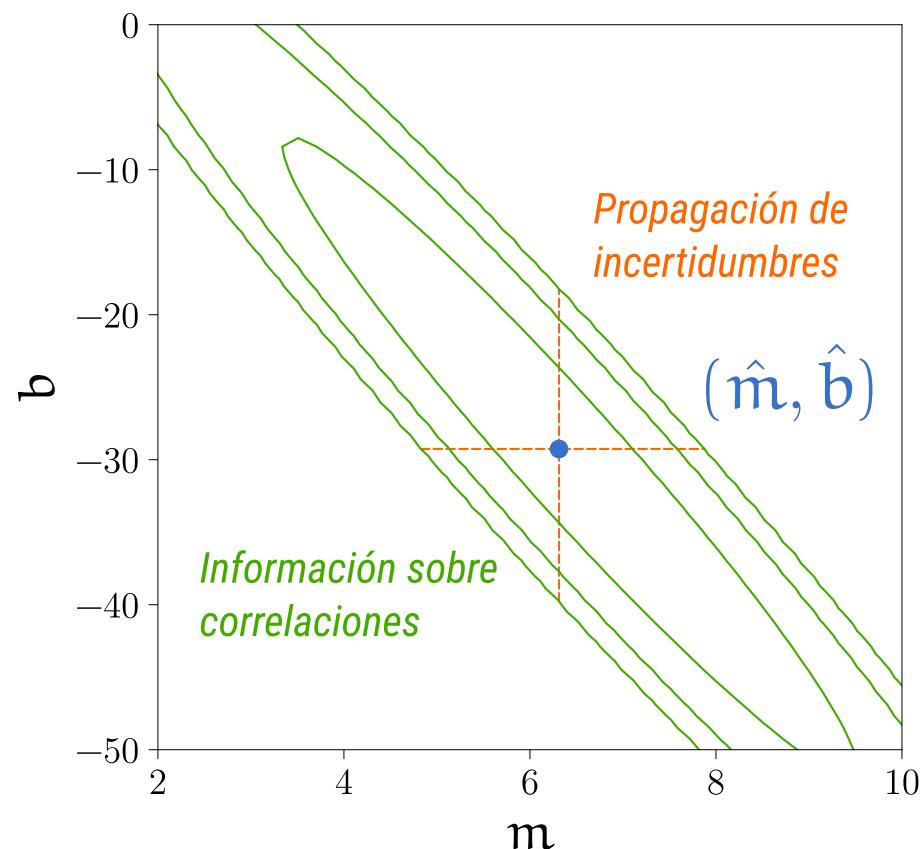
Un solo punto en el espacio de parámetros: ¡DECEPCIONANTE!

# VEROSIMILITUD – REGRESIÓN LINEAL

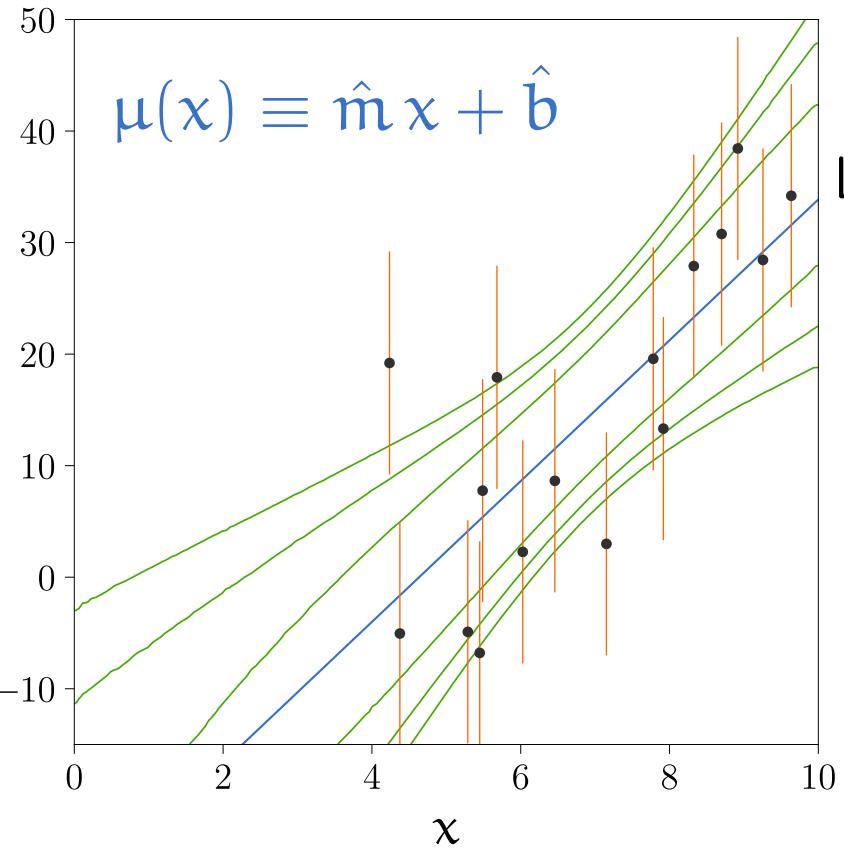


$\mathcal{L}_{\max} \equiv \mathcal{L}(\hat{m}, \hat{b} | \{y\}, \{x\}, \{\sigma_y\})$   $\mathcal{L}(m, b | \{y\}, \{x\}, \{\sigma_y\})$

Máxima Verosimilitud      Verosimilitud



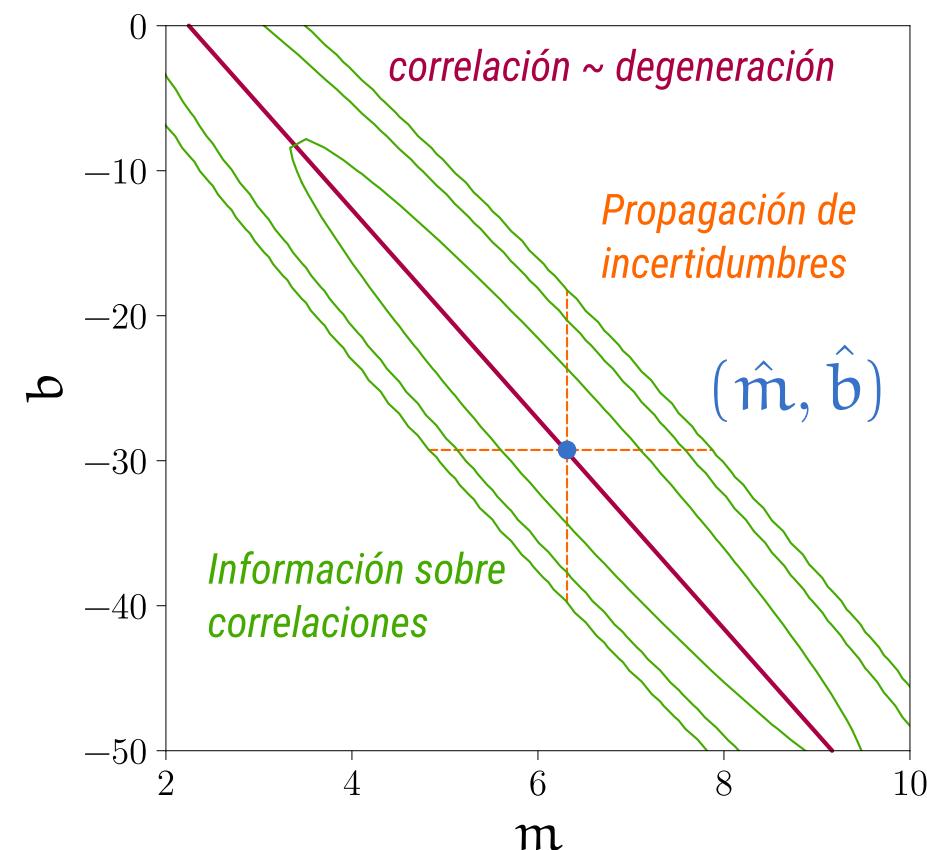
# VEROSIMILITUD – REGRESIÓN LINEAL



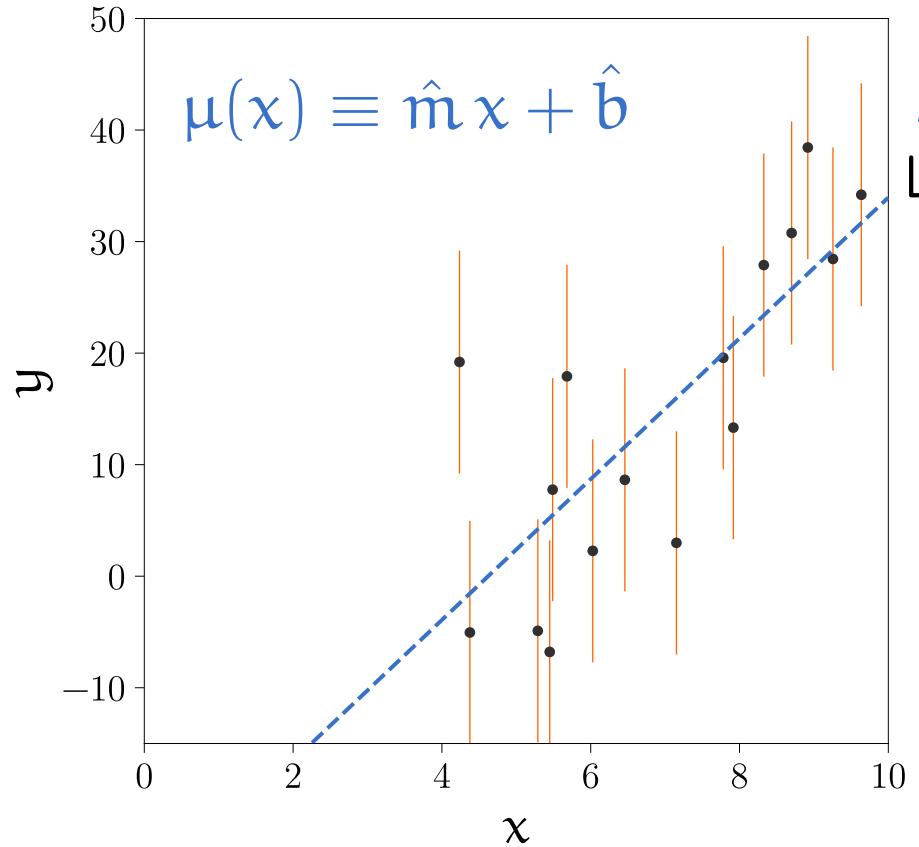
$$\mathcal{L}_{\max} \equiv \mathcal{L}(\hat{m}, \hat{b} | \{y\}, \{x\}, \{\sigma_y\}) \quad \mathcal{L}(m, b | \{y\}, \{x\}, \{\sigma_y\})$$

Máxima Verosimilitud

Verosimilitud

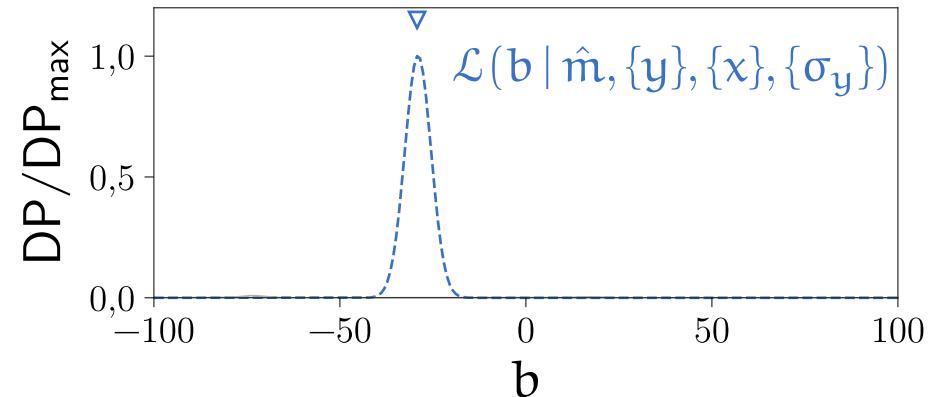
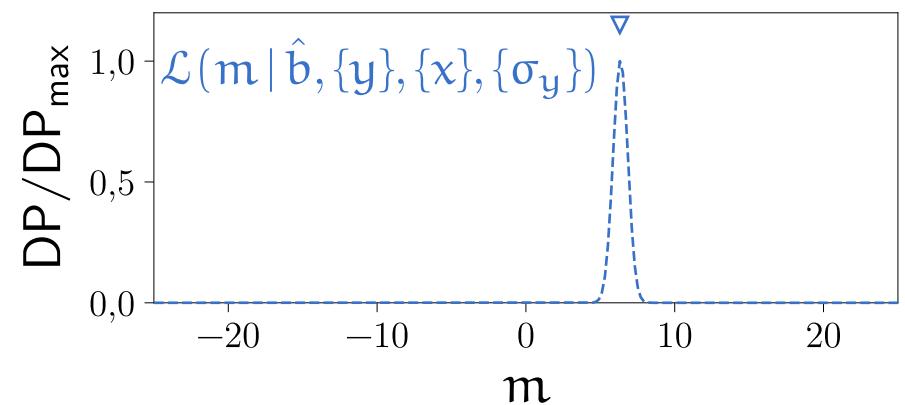


# VEROSIMILITUD – REGRESIÓN LINEAL

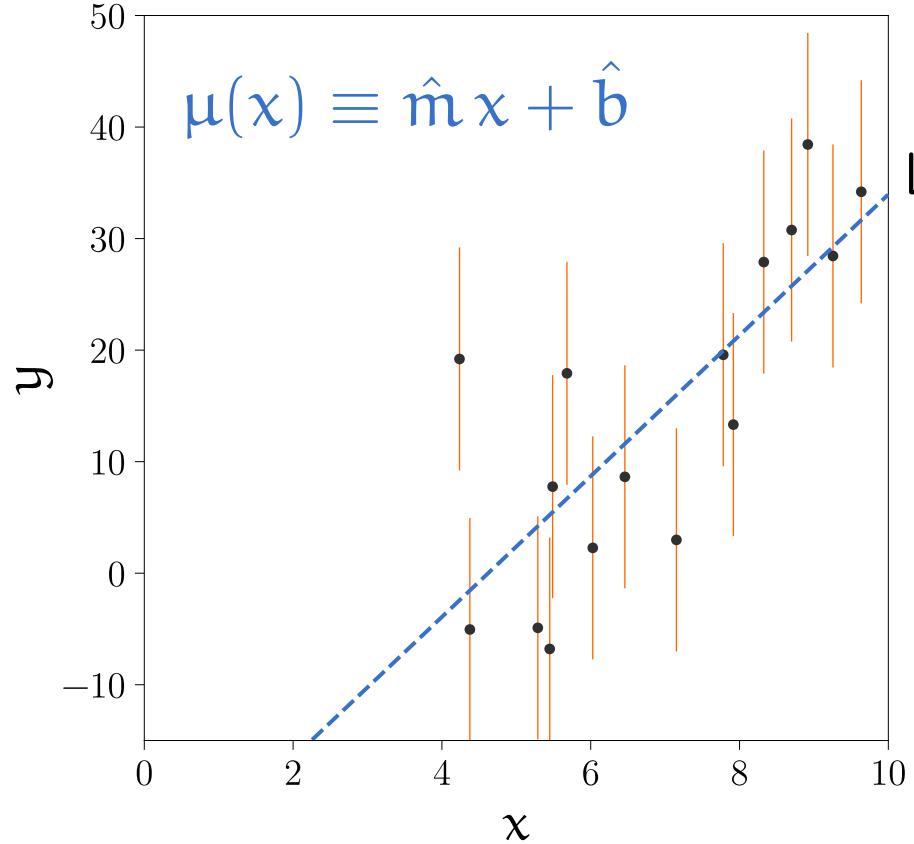


$$\mathcal{L}_{\max} \equiv \mathcal{L}(\hat{m}, \hat{b} | \{y\}, \{x\}, \{\sigma_y\})$$

Máxima Verosimilitud

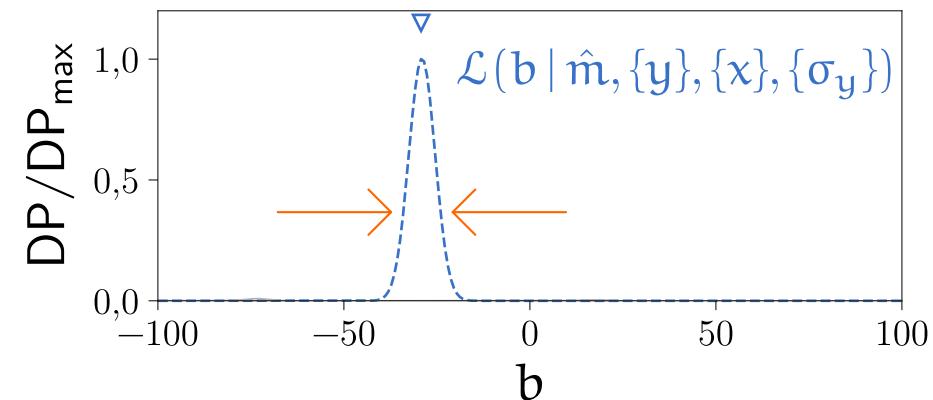
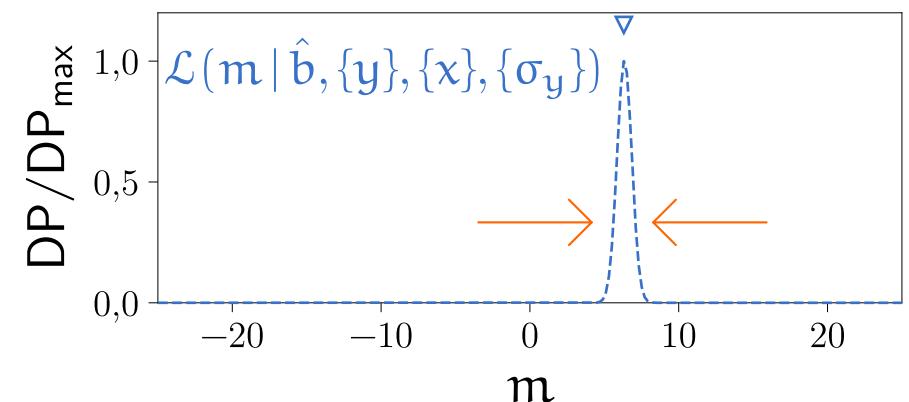


# VEROSIMILITUD – REGRESIÓN LINEAL

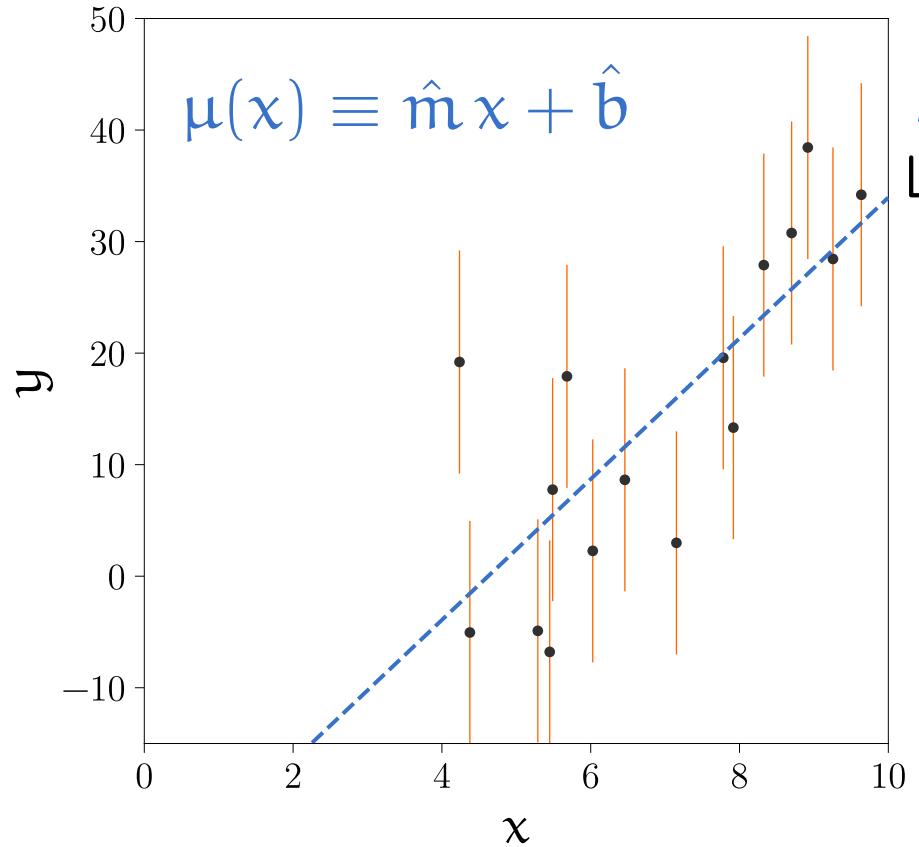


$$\mathcal{L}_{\max} \equiv \mathcal{L}(\hat{m}, \hat{b} | \{y\}, \{x\}, \{\sigma_y\})$$

Máxima Verosimilitud

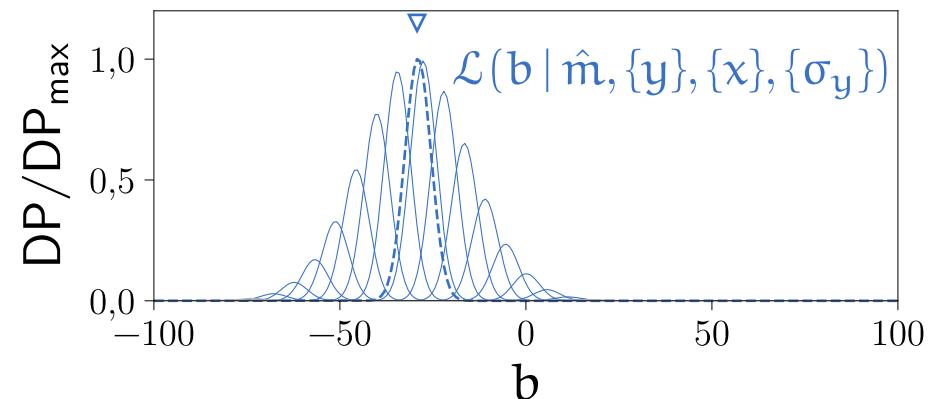
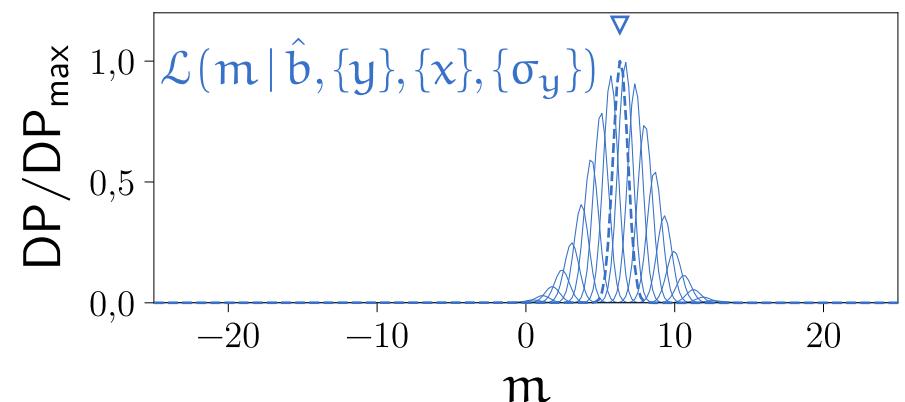


# VEROSIMILITUD – REGRESIÓN LINEAL

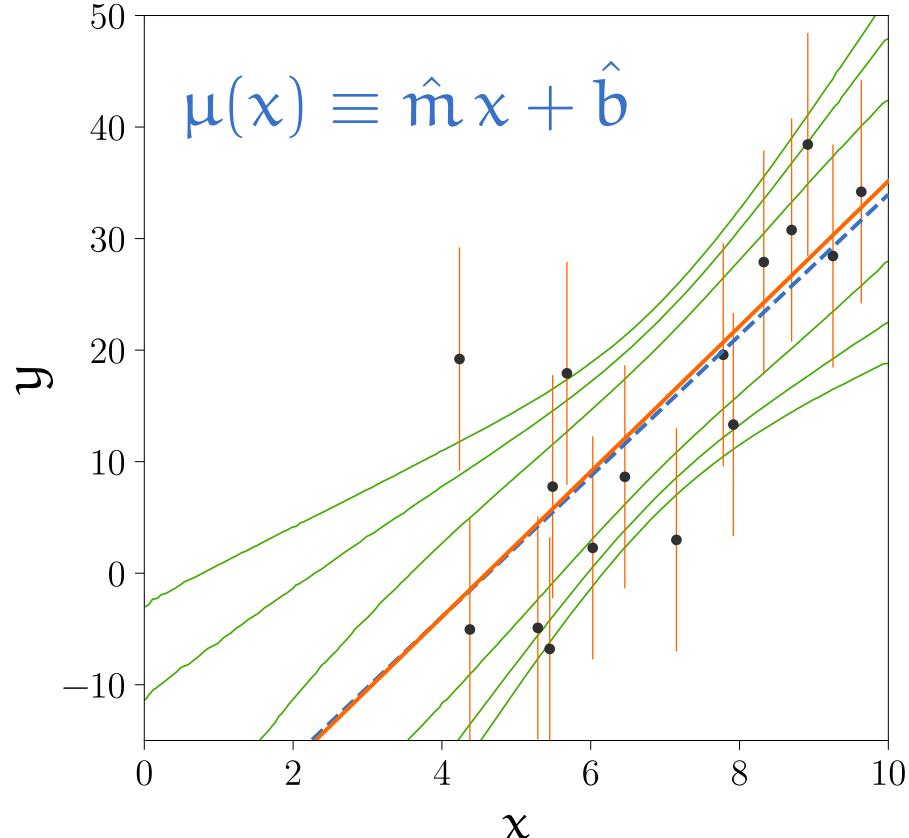


$$\mathcal{L}_{\max} \equiv \mathcal{L}(\hat{m}, \hat{b} | \{y\}, \{x\}, \{\sigma_y\})$$

Máxima Verosimilitud

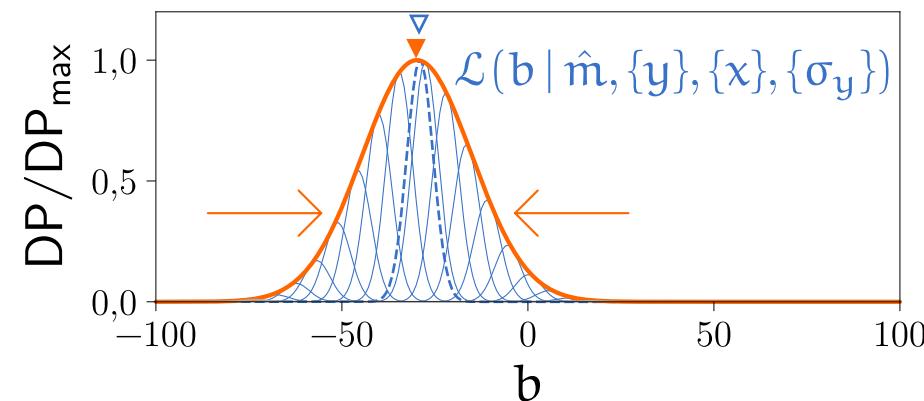
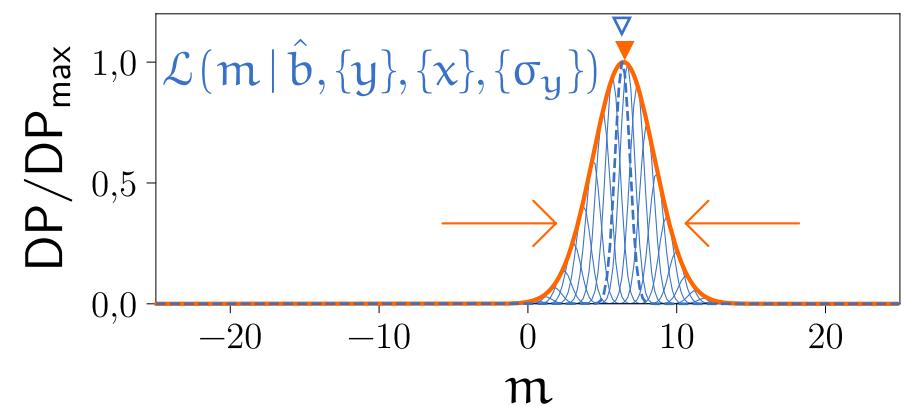


# VEROSIMILITUD – REGRESIÓN LINEAL

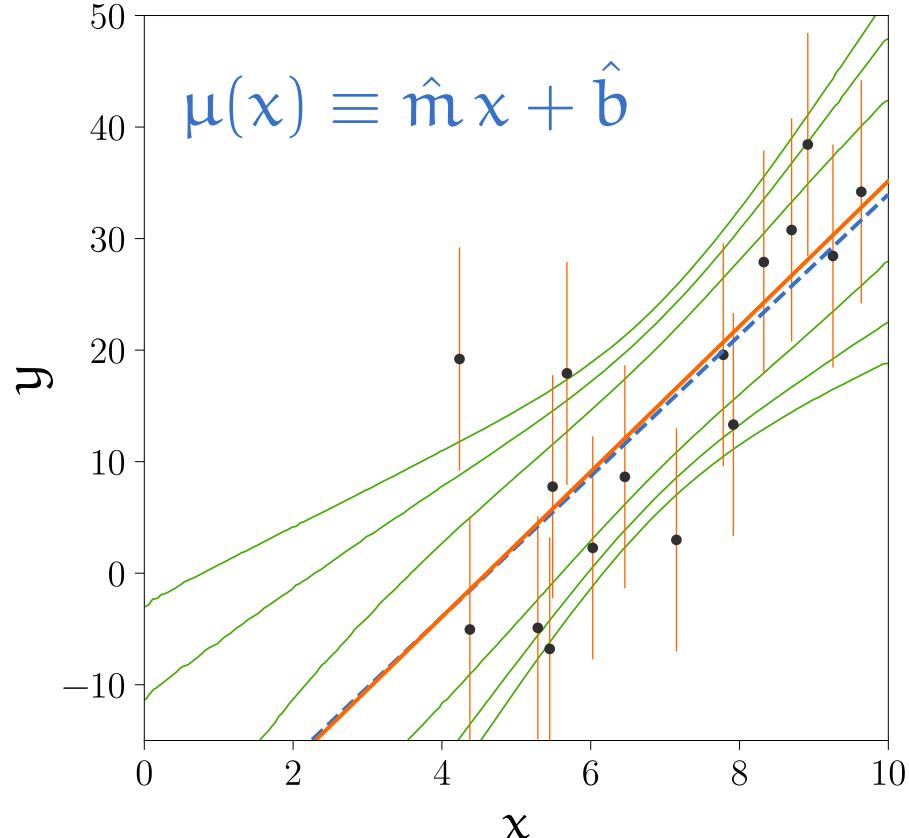


$$\mathcal{L}_{\max} \equiv \mathcal{L}(\hat{m}, \hat{b} | \{y\}, \{x\}, \{\sigma_y\})$$

Máxima Verosimilitud



# VEROSIMILITUD – REGRESIÓN LINEAL



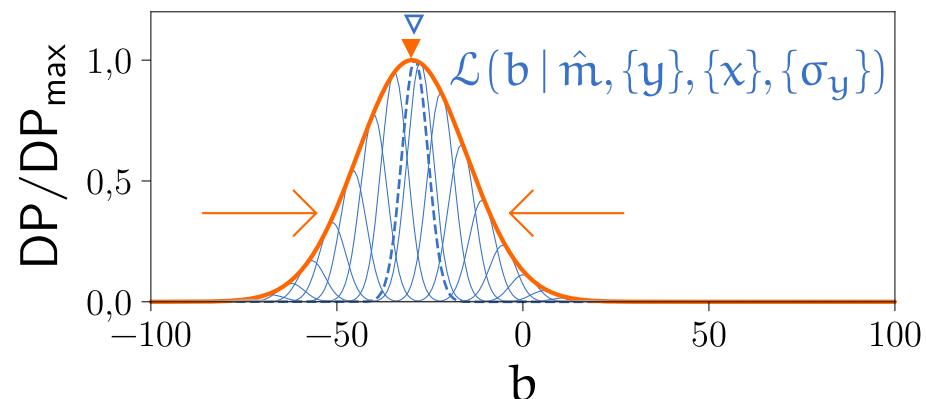
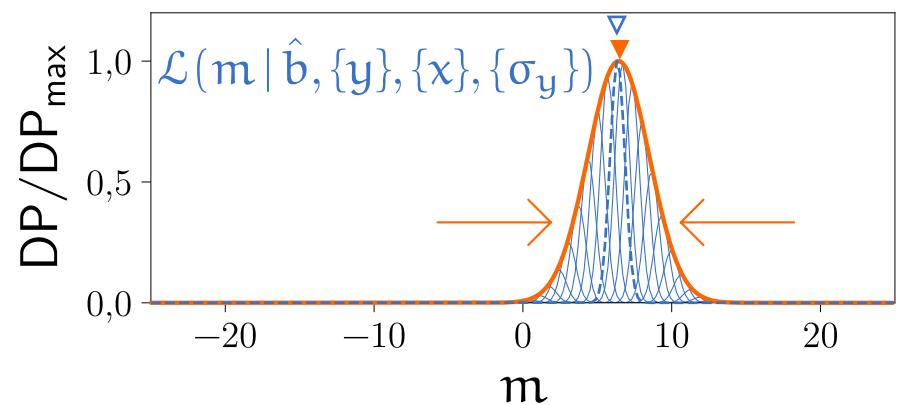
$$\mathcal{L}_{\max} \equiv \mathcal{L}(\hat{m}, \hat{b} | \{y\}, \{x\}, \{\sigma_y\})$$

Máxima Verosimilitud

La marginalización es una forma de propagar incertidumbres

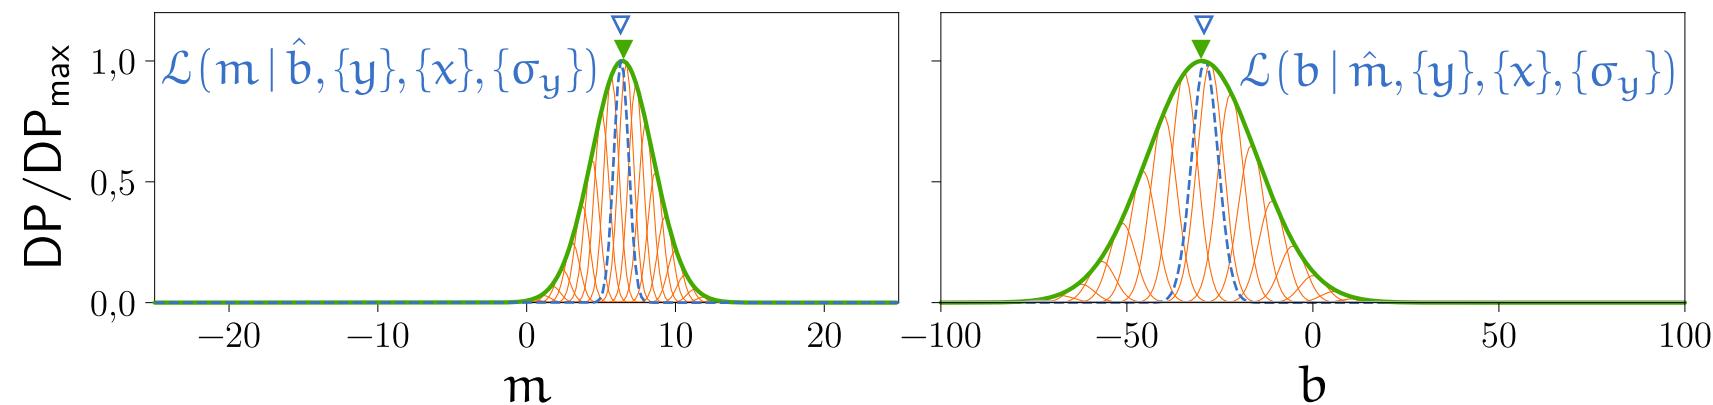
Verosimilitud marginalizada

$$\begin{aligned} \mathcal{L}(m | \{y\}, \{x\}, \{\sigma_y\}) &= \int_b \mathcal{L}(m, b | \{y\}, \{x\}, \{\sigma_y\}) \\ \mathcal{L}(b | \{y\}, \{x\}, \{\sigma_y\}) &= \int_m \mathcal{L}(m, b | \{y\}, \{x\}, \{\sigma_y\}) \end{aligned}$$



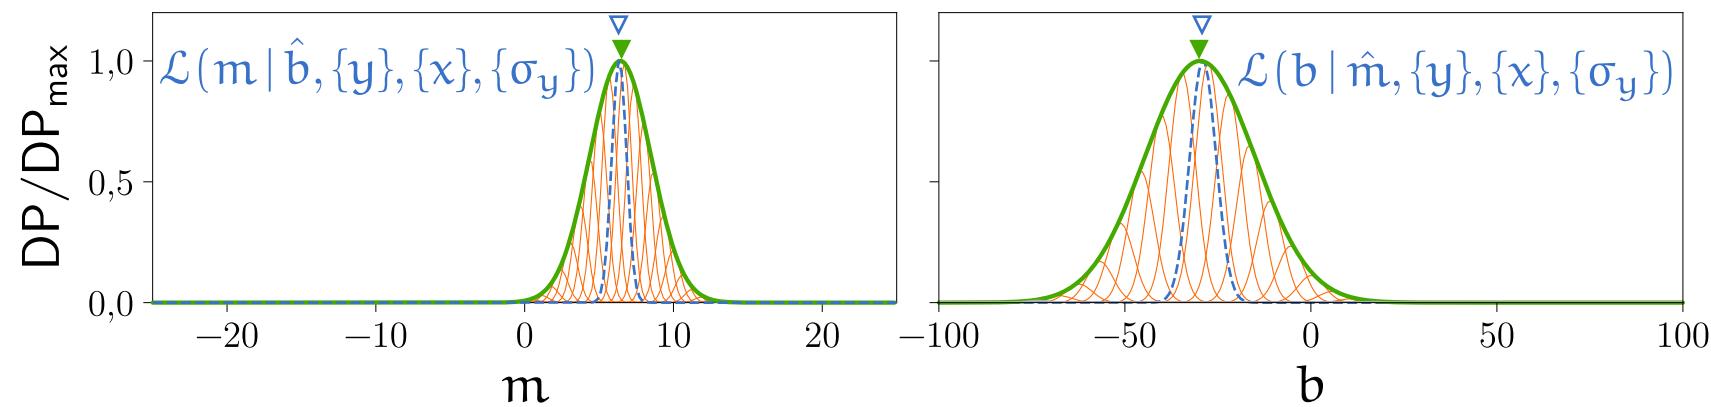
# RESUMEN – VERO SIMILITUD

- El método de la **Máxima Verosimilitud** no informa sobre **degeneraciones** ni sobre **incertidumbres**.
- La **Verosimilitud Condicional** es buena en el límite de incertidumbres pequeñas en las observaciones.
- La **marginalización** es una forma de propagar las incertidumbres en el espacio de hipótesis.
- Un análisis completo (incertidumbres+degeneraciones) requiere del **muestreo de la verosimilitud**.



# RESUMEN – VERO SIMILITUD

- El método de la **Máxima Verosimilitud** no informa sobre **degeneraciones** ni sobre **incertidumbres**.
- La **Verosimilitud Condicional** es buena en el límite de incertidumbres pequeñas en las observaciones.
- La **marginalización** es una forma de propagar las incertidumbres en el espacio de hipótesis.
- Un análisis completo (incertidumbres+degeneraciones) requiere del **muestreo de la Verosimilitud**.



*¿Cuál es la mejor forma de muestrear la verosimilitud?*

# TEOREMA DE BAYES – INTERPRETACIÓN

$$P(\mathcal{H} | \mathcal{D}, \mathcal{C}) = \frac{\mathcal{L}(\mathcal{H} | \mathcal{D}, \mathcal{C}) \times P(\mathcal{H} | \mathcal{C})}{P(\mathcal{D} | \mathcal{C})}$$

*La distribución previa se convierte en la distribución posterior*

*La observación actualiza el estado de la hipótesis*

*La verosimilitud pondera la distribución previa*

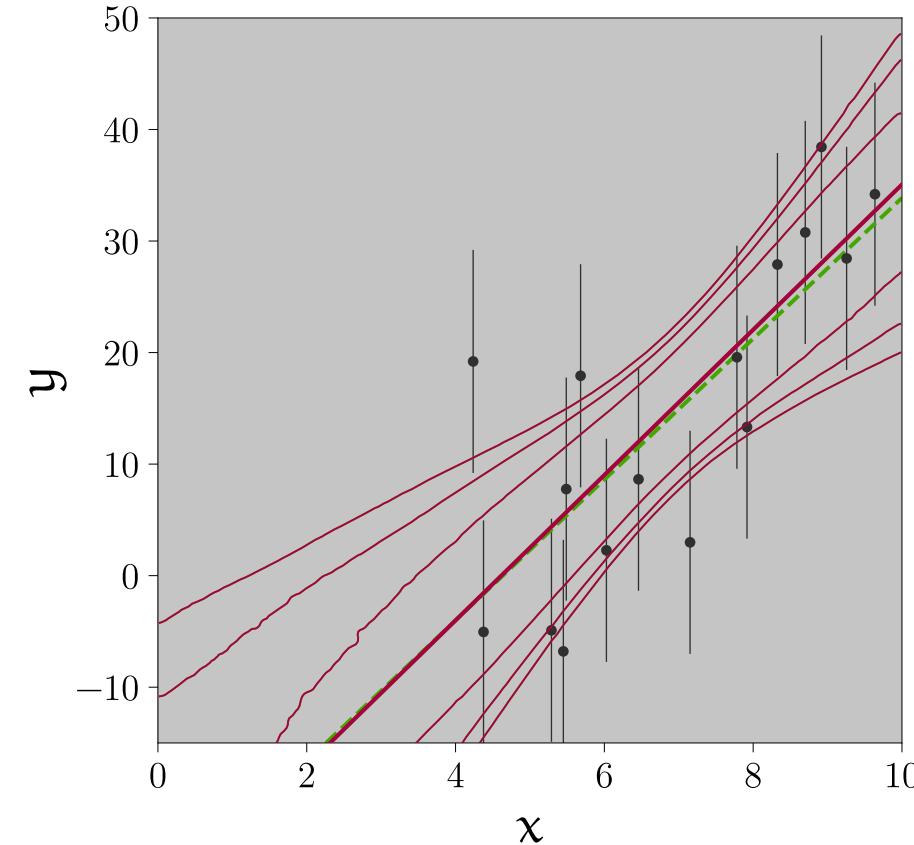
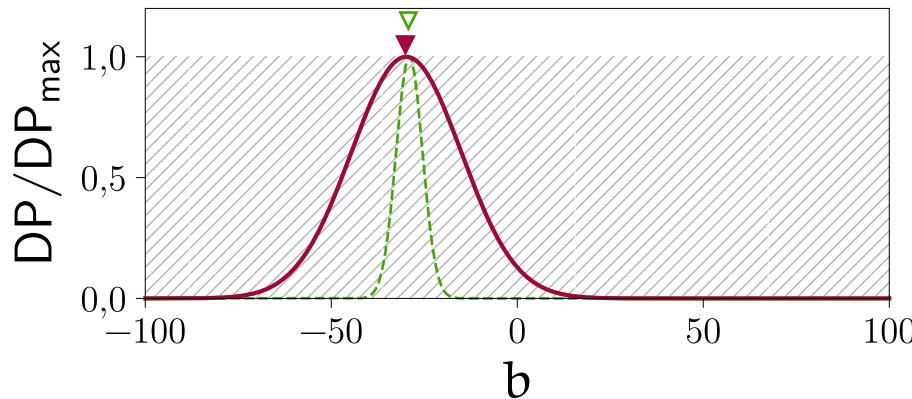
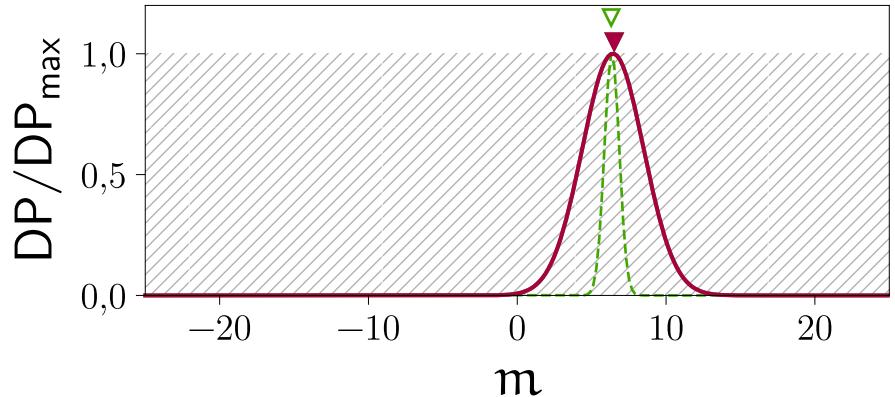
# TEOREMA DE BAYES – OPERACIÓN COMPUTACIONAL

La muestra puede convertirse  
en muestra de la  
distribución posterior

Se muestrea la  
distribución previa

$$P(\mathcal{H} | \mathcal{D}, \mathcal{C}) = \frac{\mathcal{L}(\mathcal{H} | \mathcal{D}, \mathcal{C}) \times P(\mathcal{H} | \mathcal{C})}{P(\mathcal{D} | \mathcal{C})}$$

# EL ROL DE LA DISTRIBUCIÓN PREVIA



*Si la distribución previa es plana, la distribución posterior = verosimilitud.*

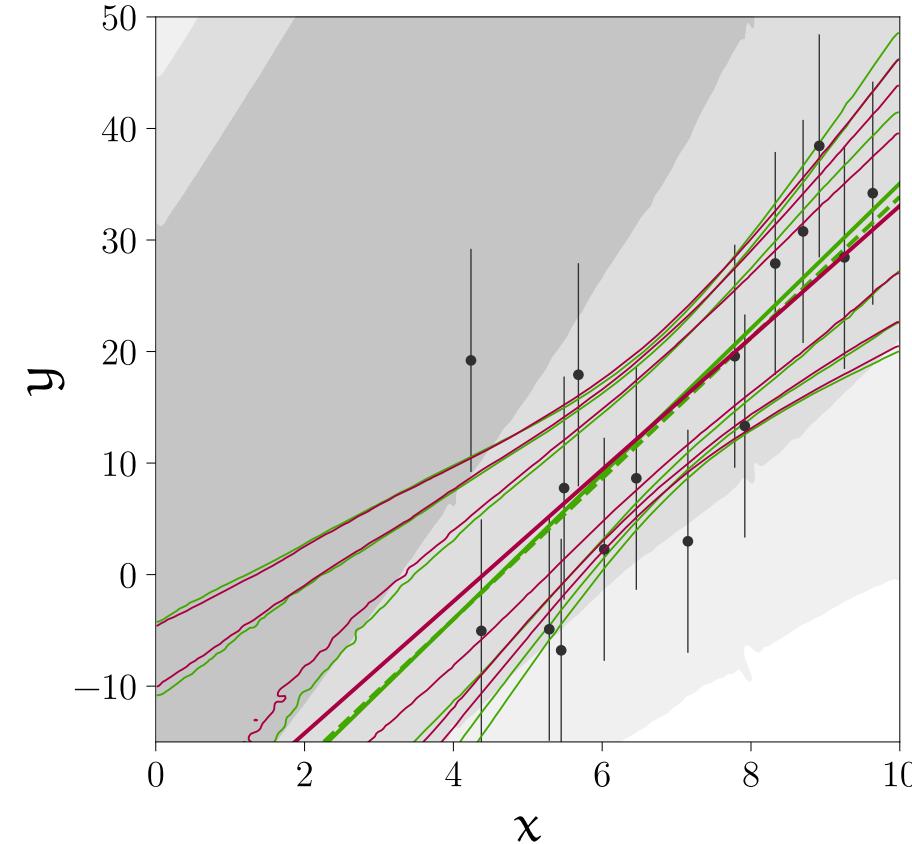
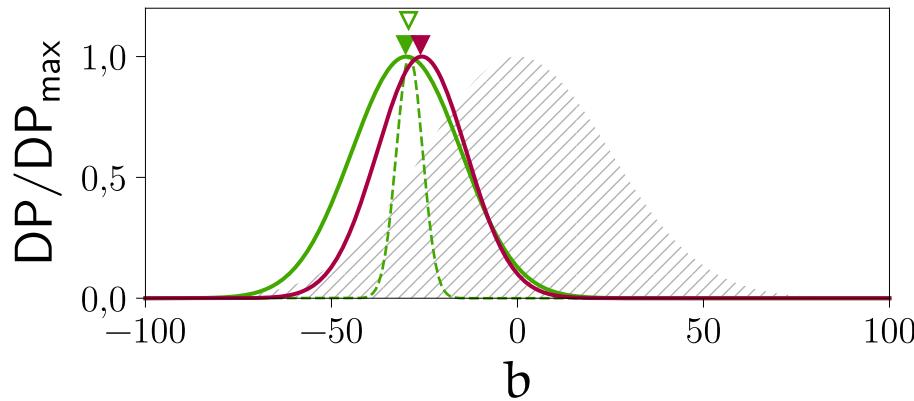
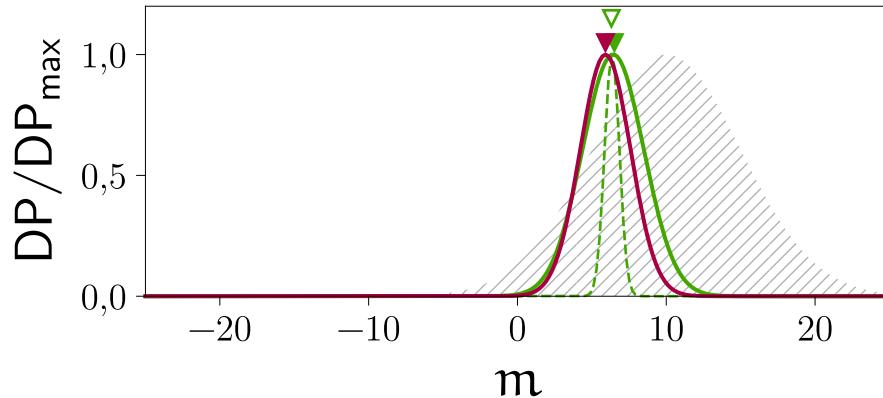
$$P(m, b | \{y\}, \{x\}, \{\sigma_y\}) \propto \mathcal{L}(m, b | \{y\}, \{x\}, \{\sigma_y\}) \times P(m, b | \{x\}, \{\sigma_y\})$$

Distribución Posterior

Función de Verosimilitud

Distribución Previa

# EL ROL DE LA DISTRIBUCIÓN PREVIA



*Aún con una distribución previa informativa la distribución posterior puede ser similar a la verosimilitud!*

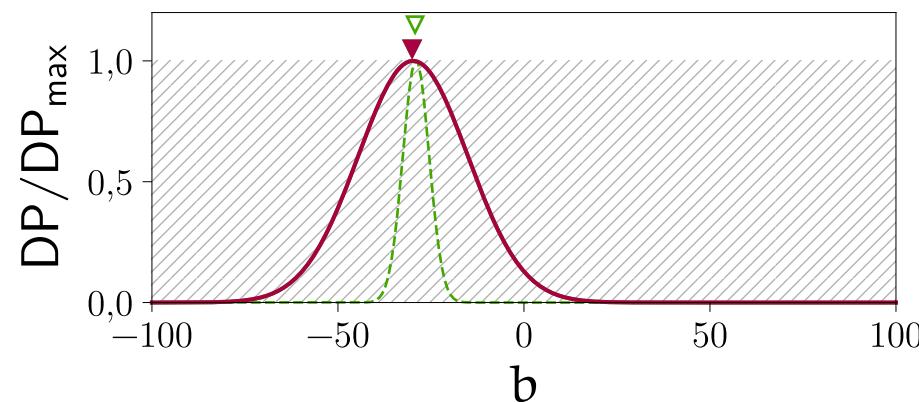
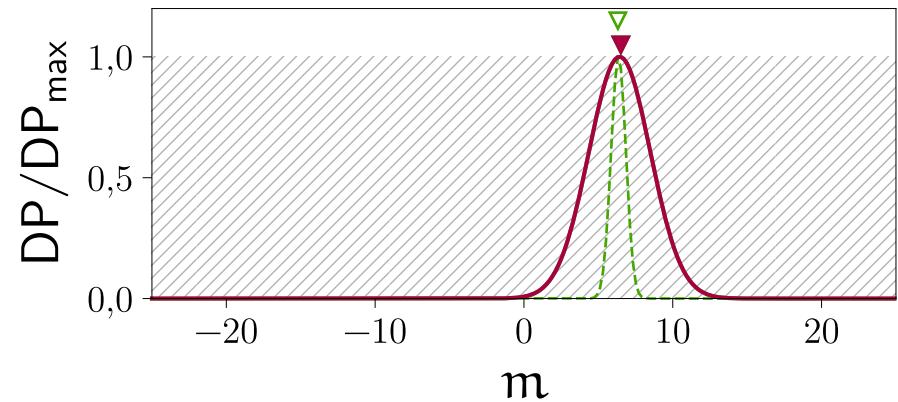
$$P(m, b | \{y\}, \{x\}, \{\sigma_y\}) \propto \mathcal{L}(m, b | \{y\}, \{x\}, \{\sigma_y\}) \times P(m, b | \{x\}, \{\sigma_y\})$$

Distribución Posterior

Función de Verosimilitud

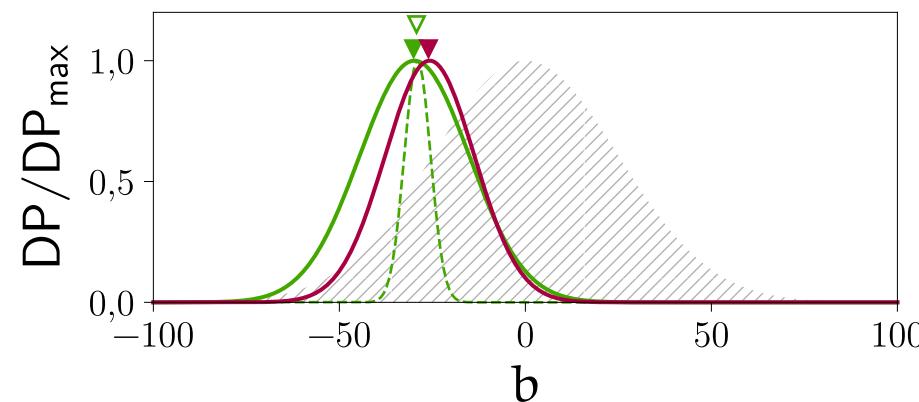
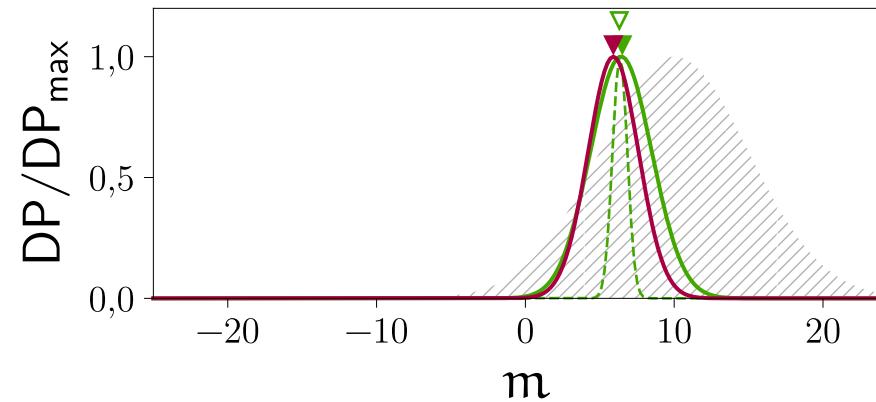
Distribución Previa

# EL ROL DE LA DISTRIBUCIÓN PREVIA



Distribución Previa Objetiva

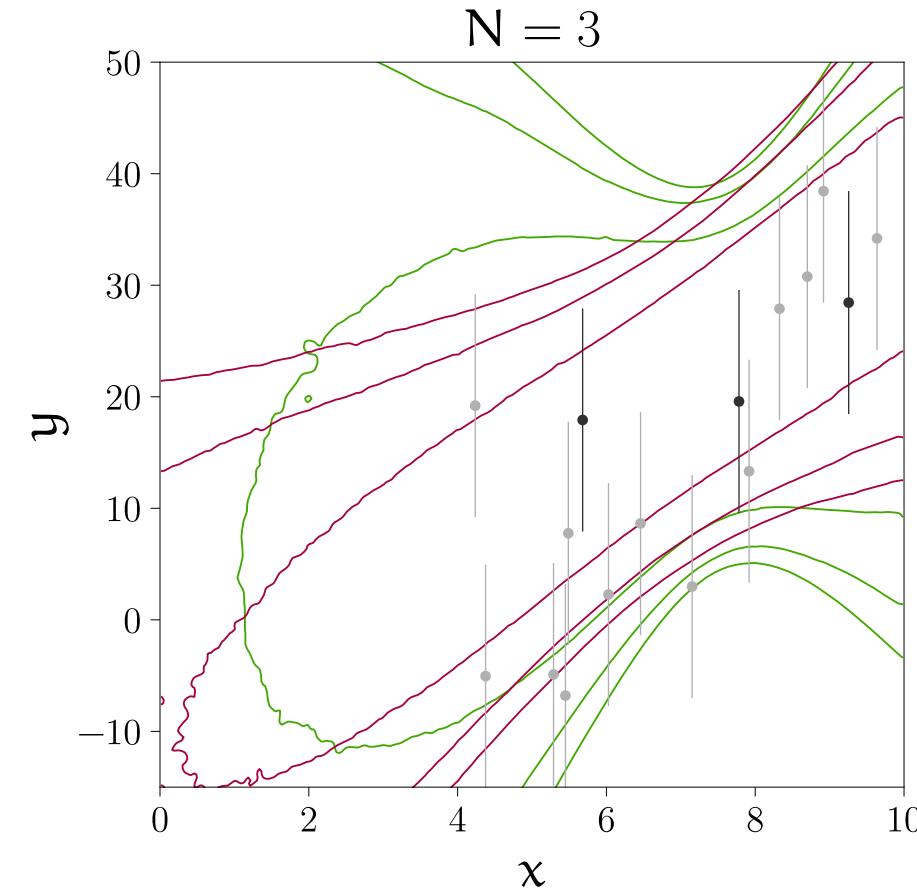
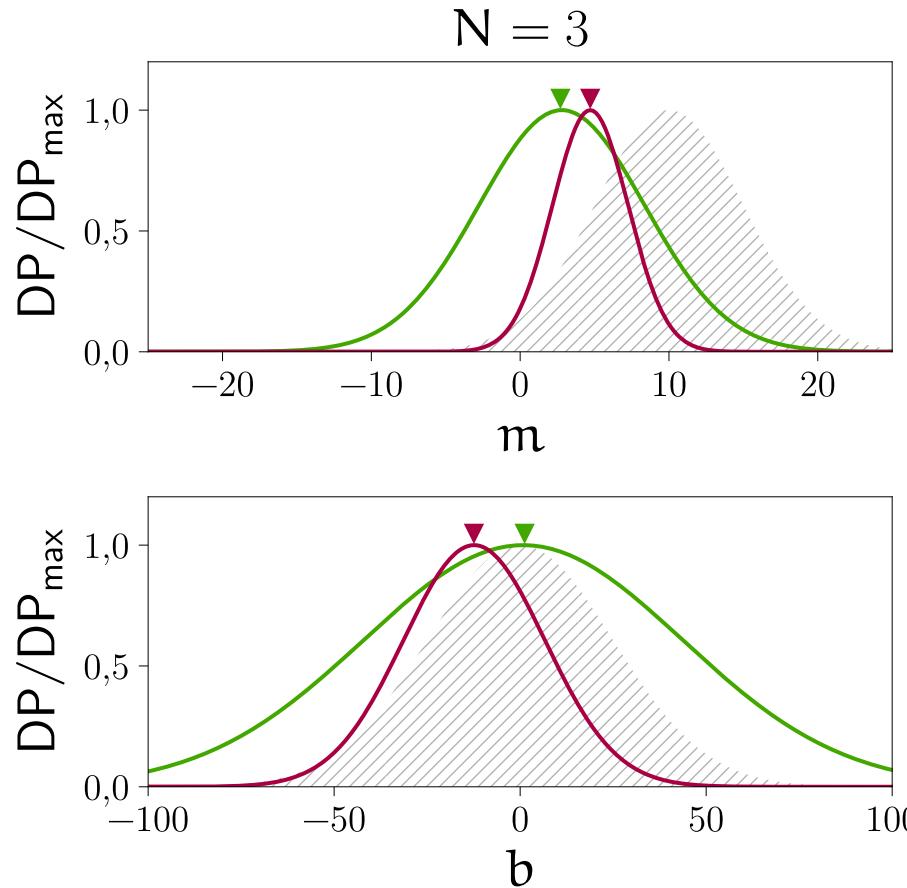
*Puede limitar el avance de la distribución posterior.*



Distribución Previa Informativa

*Puede plagar de prejuicios la distribución posterior.*

# EL ROL DE LA DISTRIBUCIÓN PREVIA – NÚMERO DE OBSERVACIONES



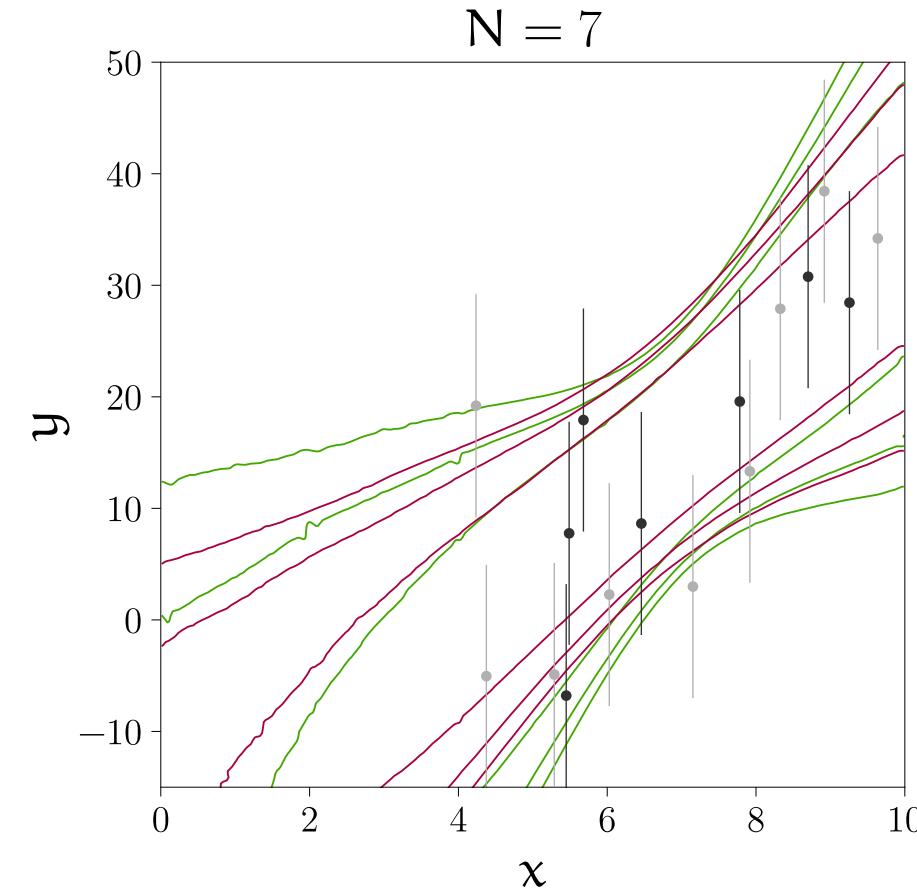
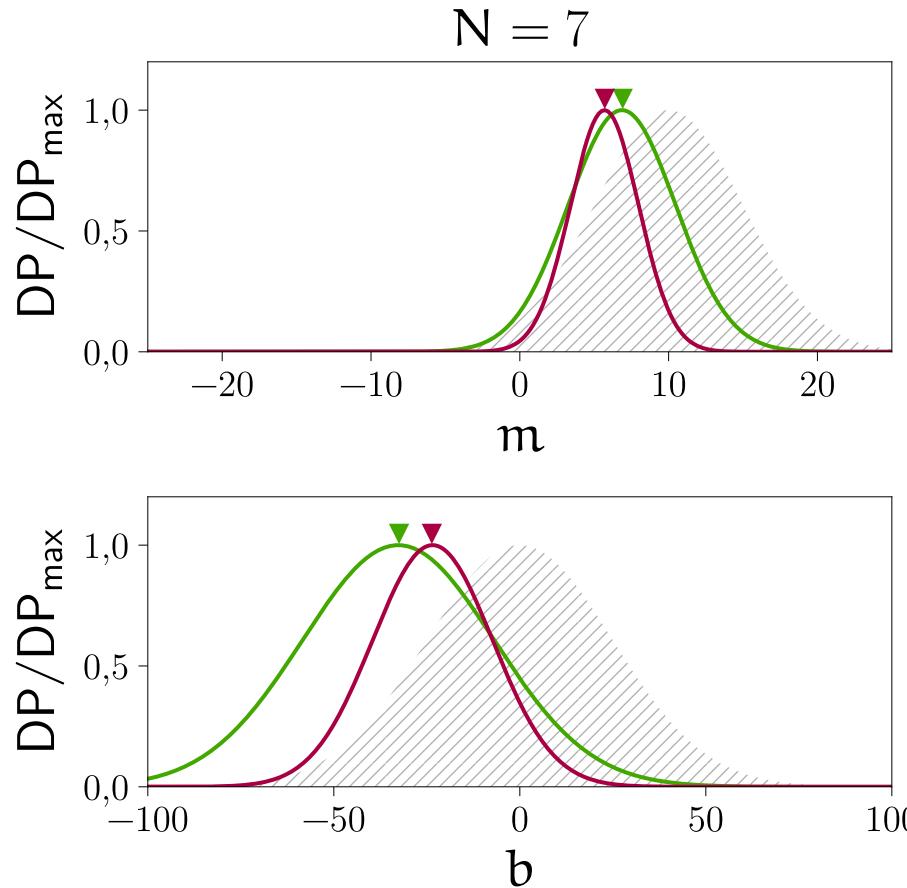
$$P(m, b | \{y\}, \{x\}, \{\sigma_y\}) \propto \mathcal{L}(m, b | \{y\}, \{x\}, \{\sigma_y\}) \times P(m, b | \{x\}, \{\sigma_y\})$$

Distribución Posterior

Función de Verosimilitud

Distribución Previa

# EL ROL DE LA DISTRIBUCIÓN PREVIA – NÚMERO DE OBSERVACIONES



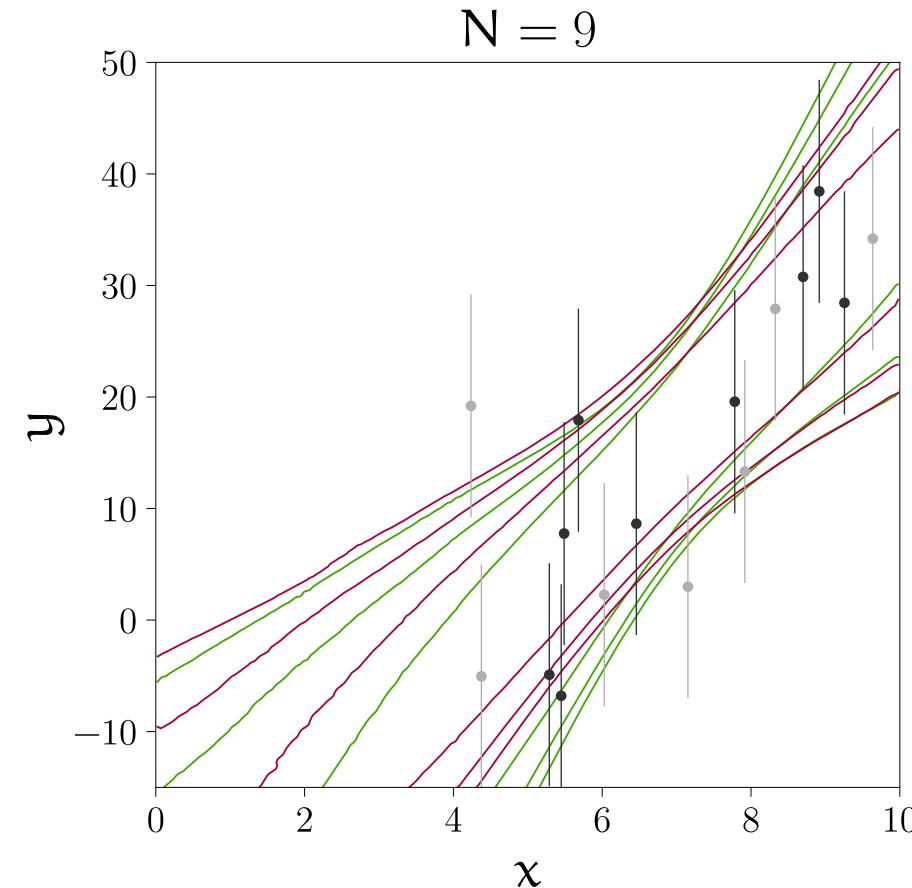
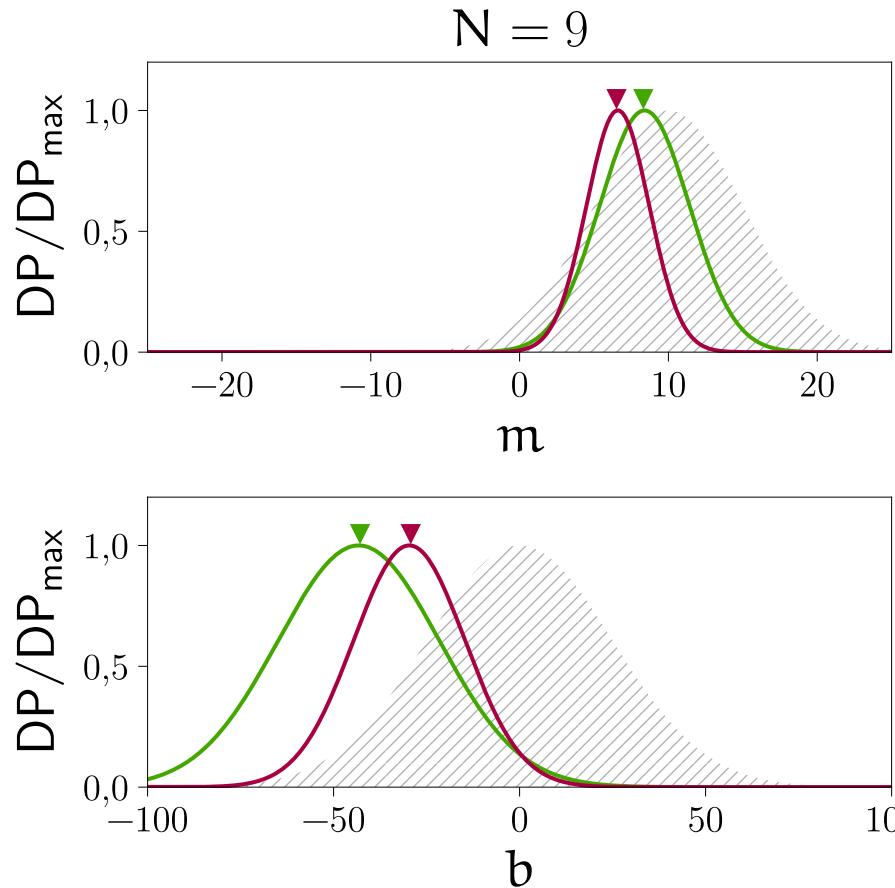
$$P(m, b | \{y\}, \{x\}, \{\sigma_y\}) \propto \mathcal{L}(m, b | \{y\}, \{x\}, \{\sigma_y\}) \times P(m, b | \{x\}, \{\sigma_y\})$$

Distribución Posterior

Función de Verosimilitud

Distribución Previa

# EL ROL DE LA DISTRIBUCIÓN PREVIA – NÚMERO DE OBSERVACIONES



$$P(m, b | \{y\}, \{x\}, \{\sigma_y\}) \propto \mathcal{L}(m, b | \{y\}, \{x\}, \{\sigma_y\}) \times P(m, b | \{x\}, \{\sigma_y\})$$

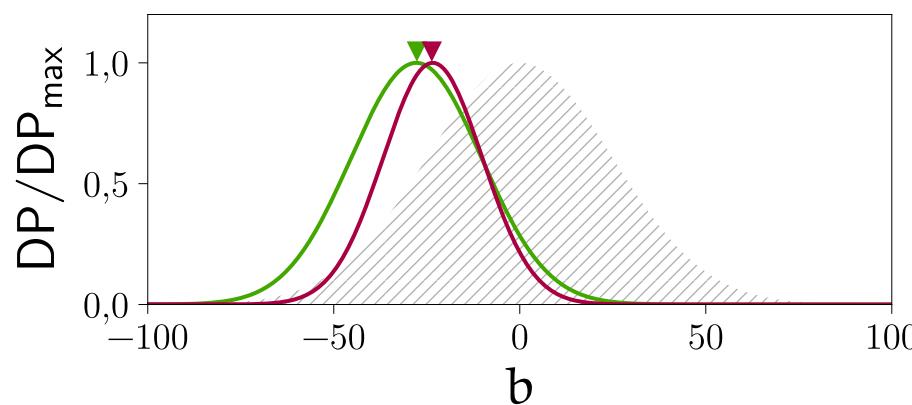
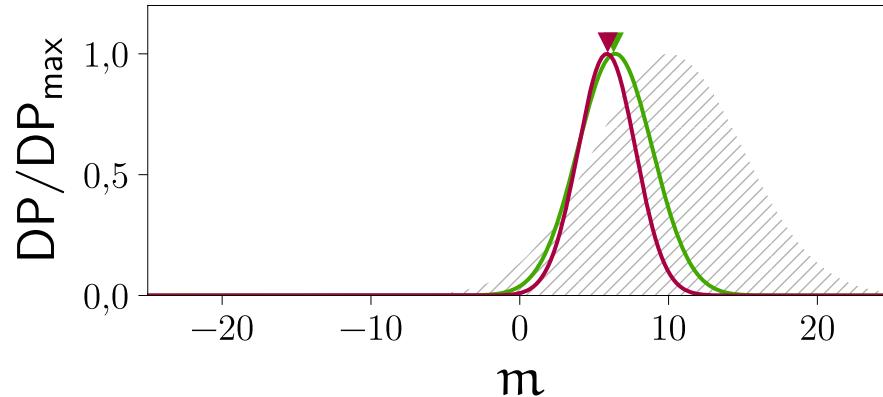
Distribución Posterior

Función de Verosimilitud

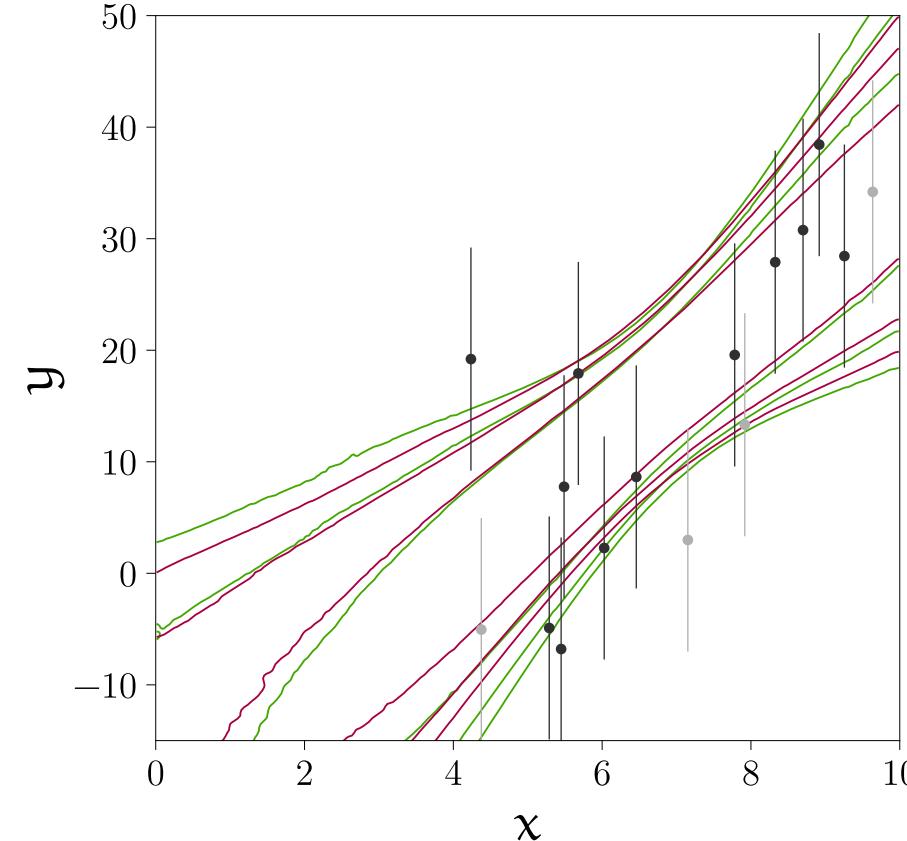
Distribución Previa

# EL ROL DE LA DISTRIBUCIÓN PREVIA – NÚMERO DE OBSERVACIONES

$N = 12$



$N = 12$



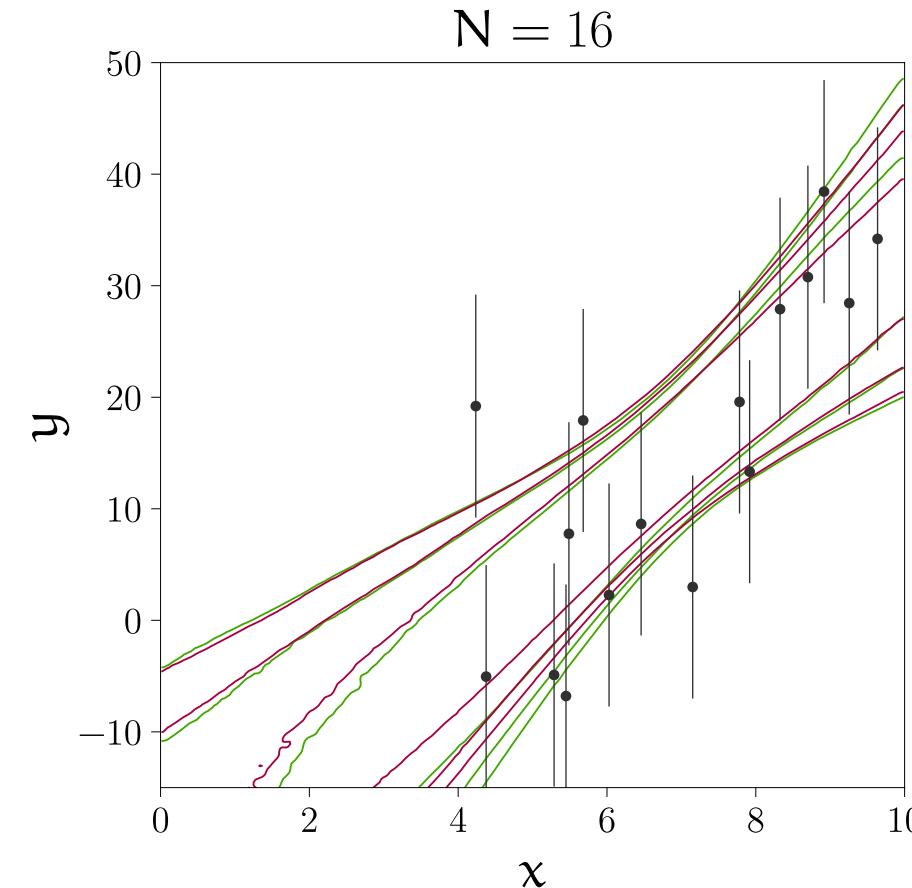
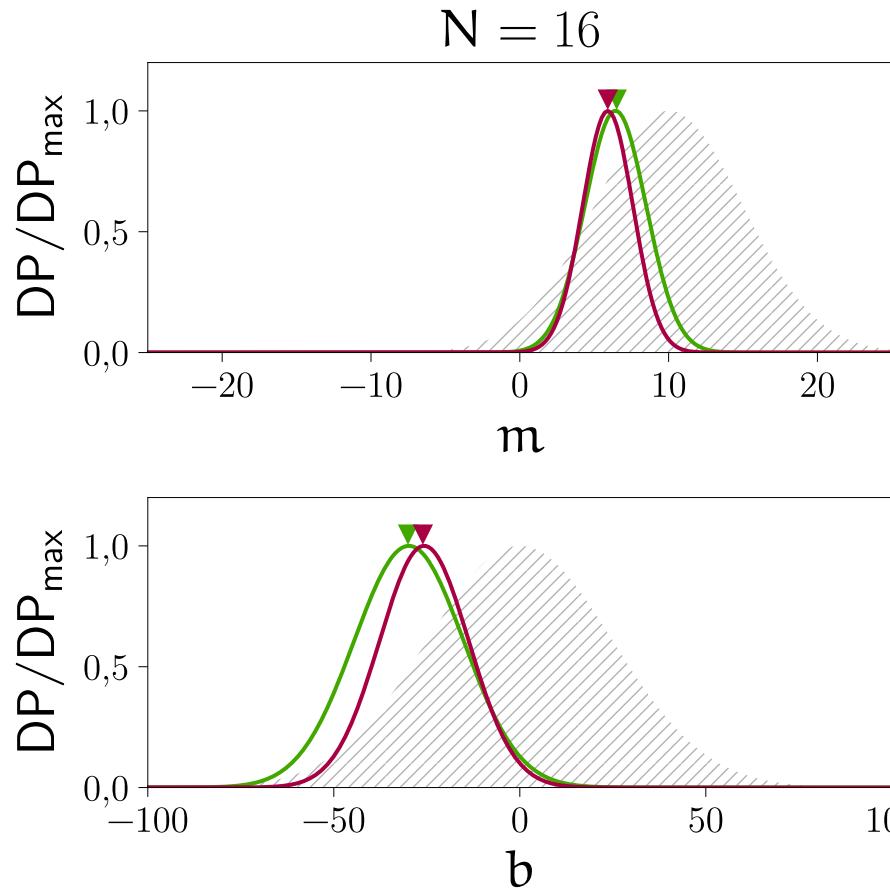
$$P(m, b | \{y\}, \{x\}, \{\sigma_y\}) \propto \mathcal{L}(m, b | \{y\}, \{x\}, \{\sigma_y\}) \times P(m, b | \{x\}, \{\sigma_y\})$$

Distribución Posterior

Función de Verosimilitud

Distribución Previa

# EL ROL DE LA DISTRIBUCIÓN PREVIA – NÚMERO DE OBSERVACIONES



*En el límite  $N \rightarrow \infty$   
la distribución previa  
se vuelve irrelevante.*

$$P(m, b | \{y\}, \{x\}, \{\sigma_y\}) \propto \mathcal{L}(m, b | \{y\}, \{x\}, \{\sigma_y\}) \times P(m, b | \{x\}, \{\sigma_y\})$$

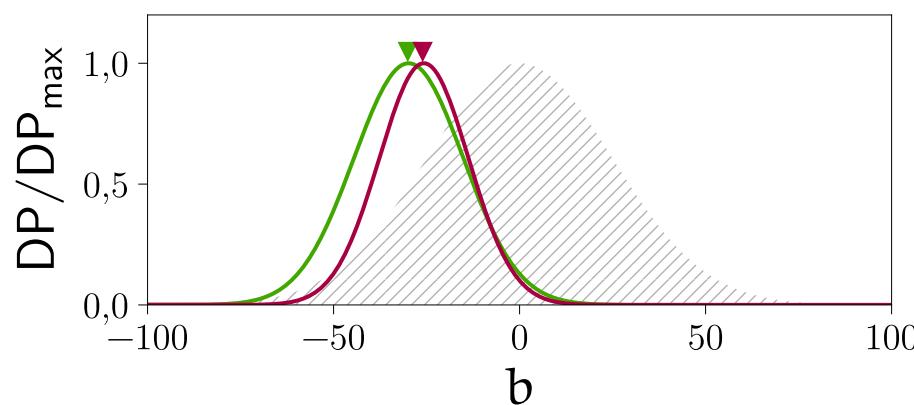
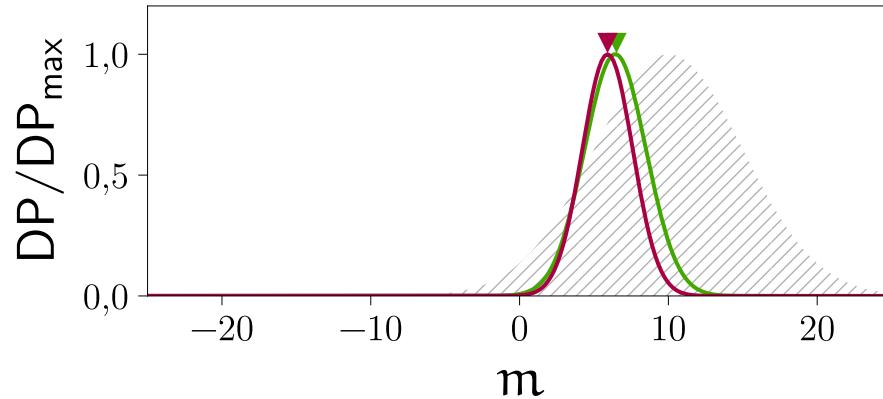
Distribución Posterior

Función de Verosimilitud

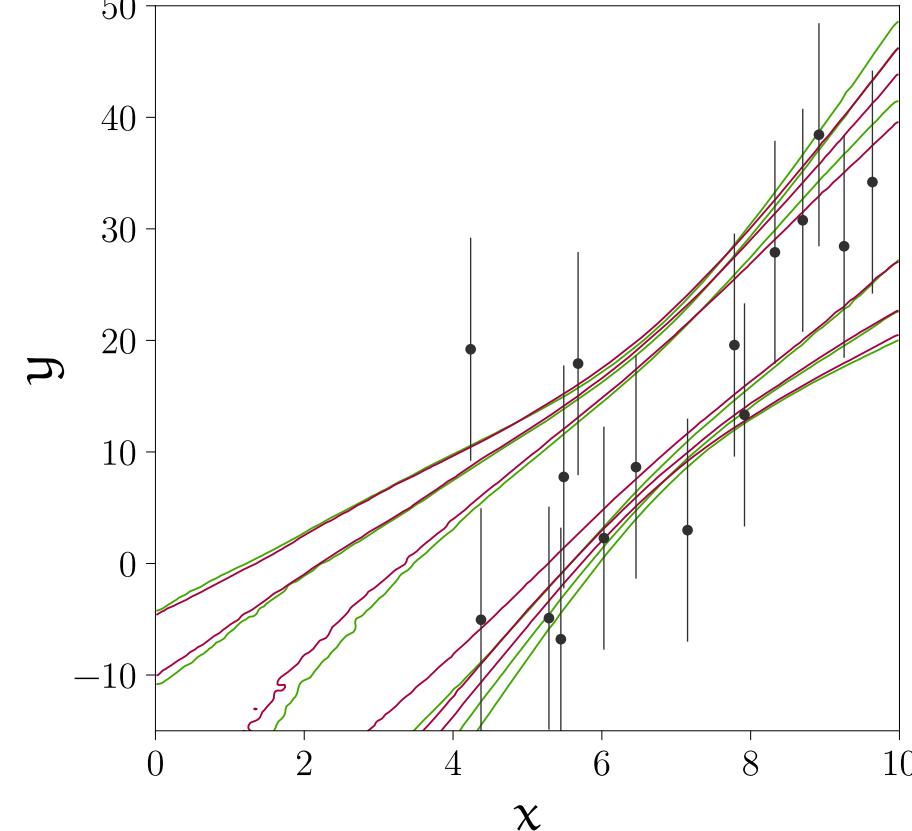
Distribución Previa

# EL ROL DE LA DISTRIBUCIÓN PREVIA – SEÑAL/RUIDO DE LAS OBSERVACIONES

$$\sigma_y = 10,0$$



$$\sigma_y = 10,0$$



$$P(m, b | \{y\}, \{x\}, \{\sigma_y\}) \propto \mathcal{L}(m, b | \{y\}, \{x\}, \{\sigma_y\}) \times P(m, b | \{x\}, \{\sigma_y\})$$

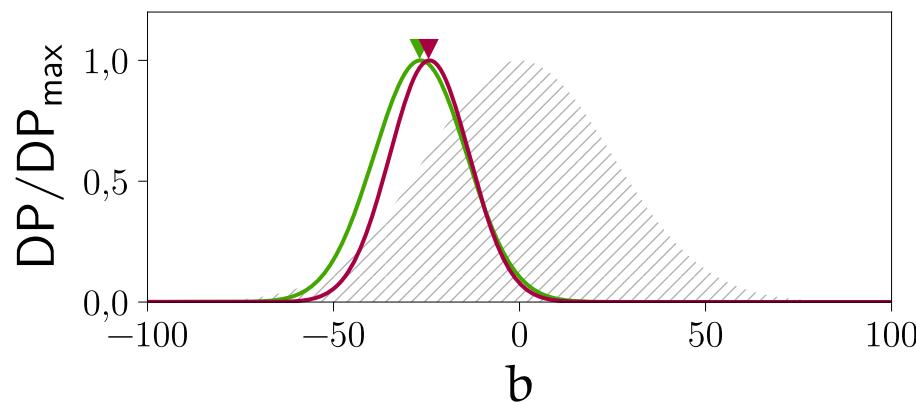
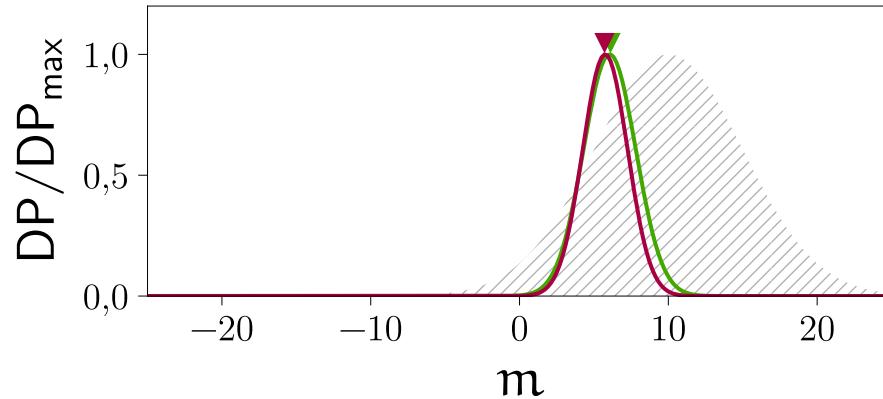
Distribución Posterior

Función de Verosimilitud

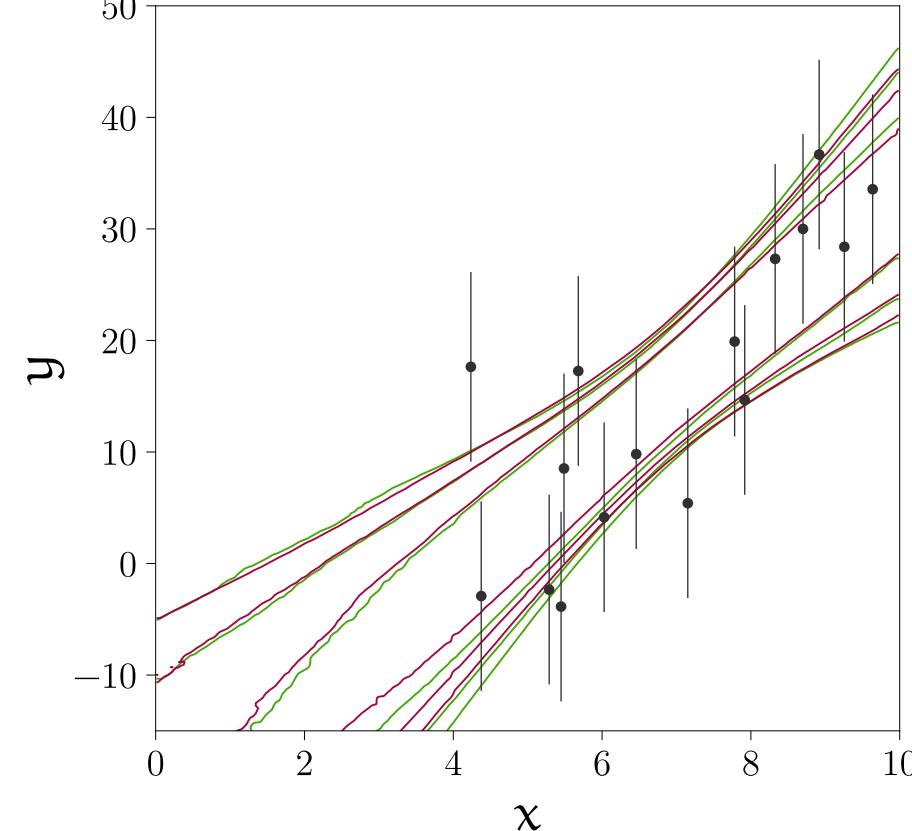
Distribución Previa

# EL ROL DE LA DISTRIBUCIÓN PREVIA – SEÑAL/RUIDO DE LAS OBSERVACIONES

$$\sigma_y = 8,5$$



$$\sigma_y = 8,5$$



$$P(m, b | \{y\}, \{x\}, \{\sigma_y\}) \propto \mathcal{L}(m, b | \{y\}, \{x\}, \{\sigma_y\}) \times P(m, b | \{x\}, \{\sigma_y\})$$

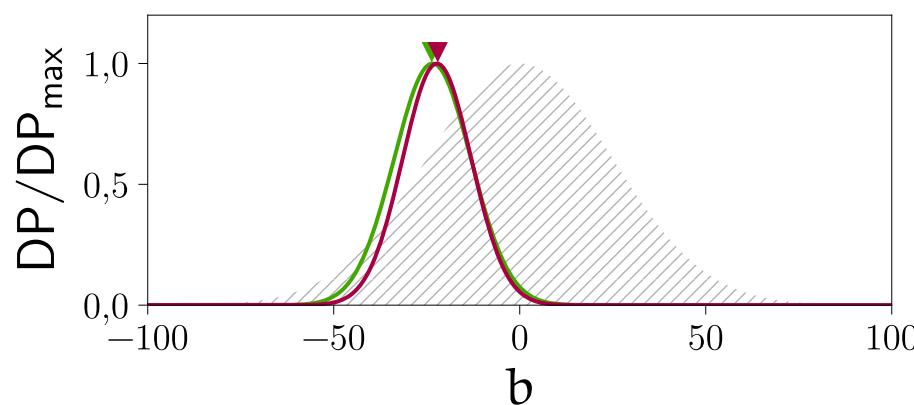
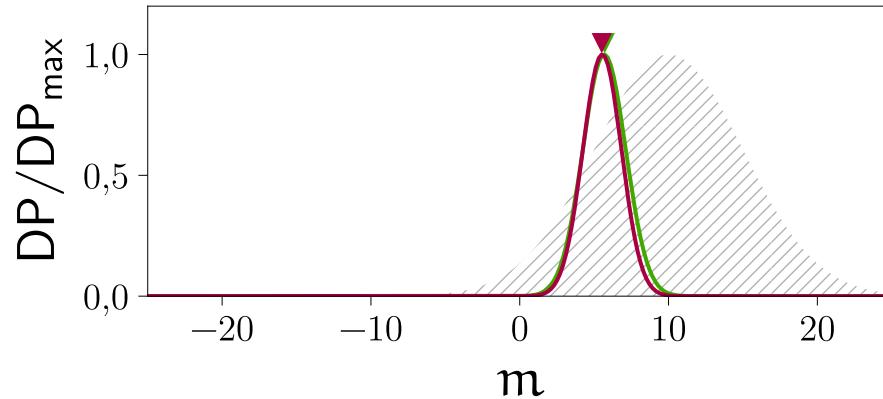
Distribución Posterior

Función de Verosimilitud

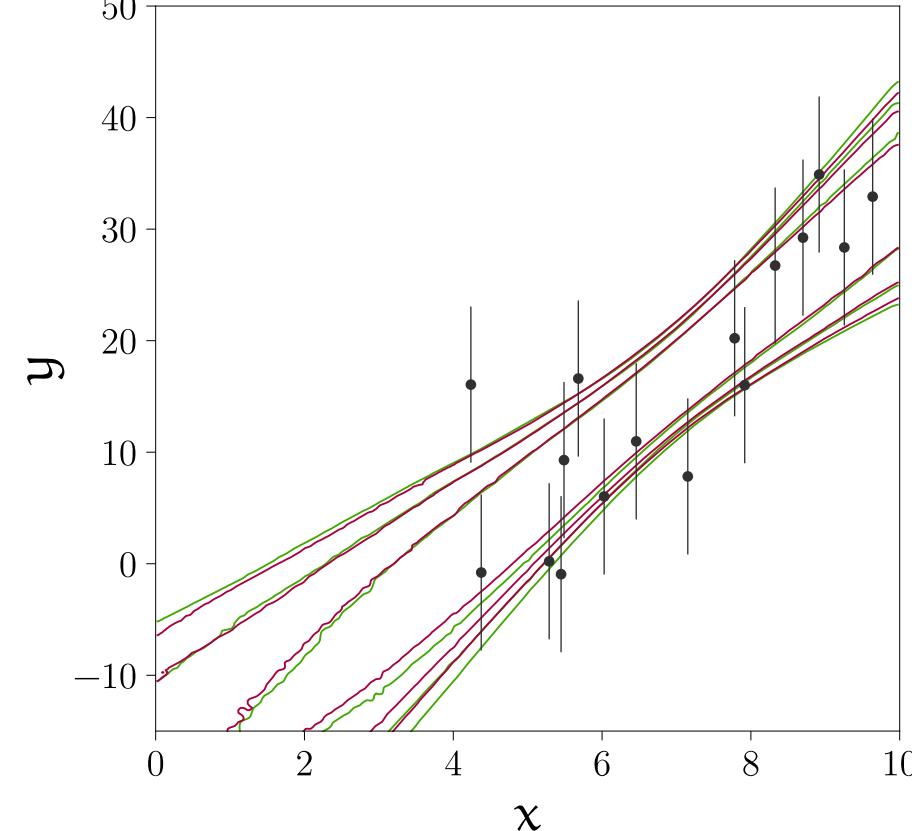
Distribución Previa

# EL ROL DE LA DISTRIBUCIÓN PREVIA – SEÑAL/RUIDO DE LAS OBSERVACIONES

$$\sigma_y = 7,0$$



$$\sigma_y = 7,0$$



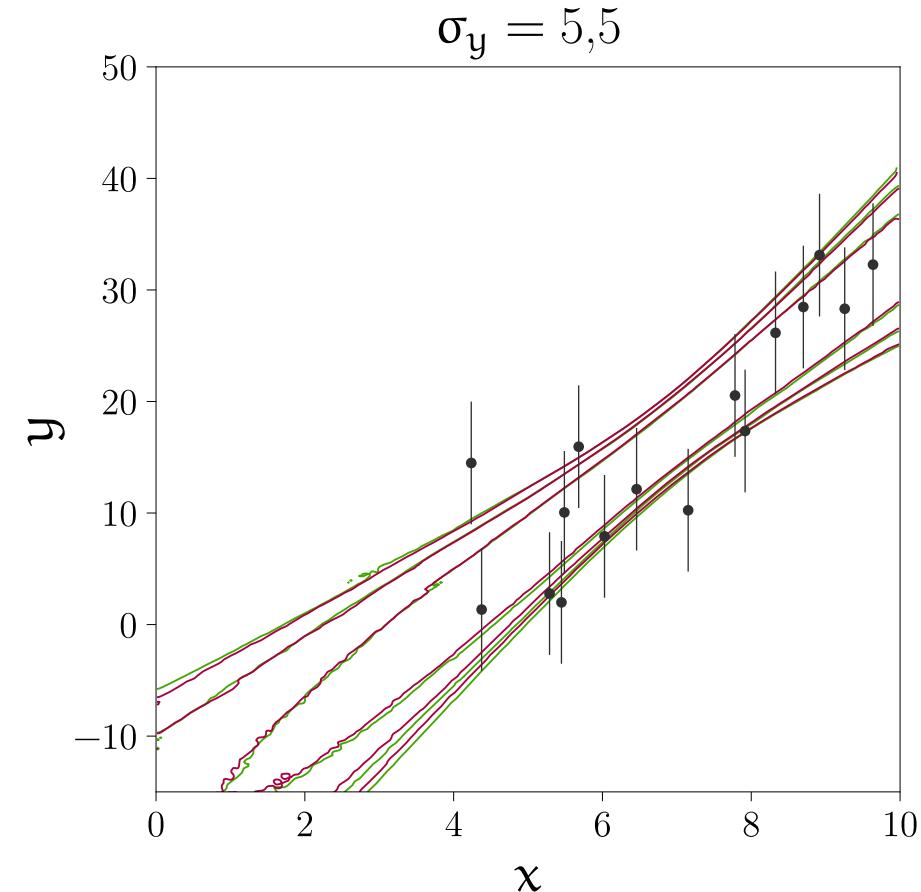
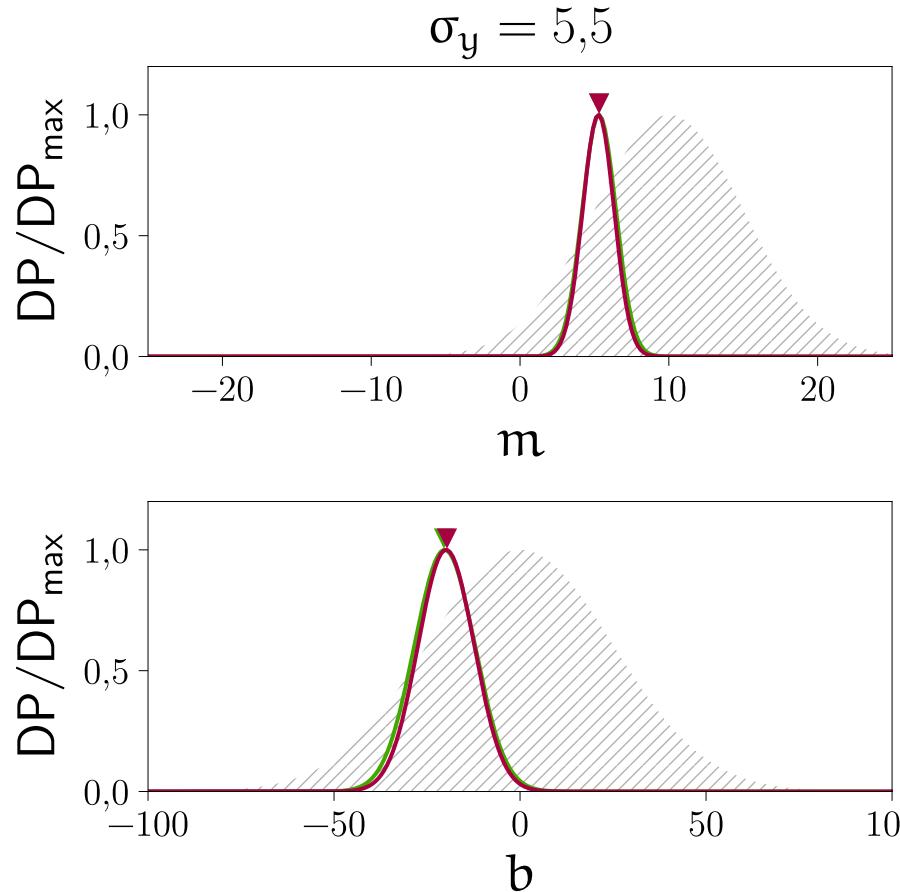
$$P(m, b | \{y\}, \{x\}, \{\sigma_y\}) \propto \mathcal{L}(m, b | \{y\}, \{x\}, \{\sigma_y\}) \times P(m, b | \{x\}, \{\sigma_y\})$$

Distribución Posterior

Función de Verosimilitud

Distribución Previa

# EL ROL DE LA DISTRIBUCIÓN PREVIA – SEÑAL/RUIDO DE LAS OBSERVACIONES



$$P(m, b | \{y\}, \{x\}, \{\sigma_y\}) \propto \mathcal{L}(m, b | \{y\}, \{x\}, \{\sigma_y\}) \times P(m, b | \{x\}, \{\sigma_y\})$$

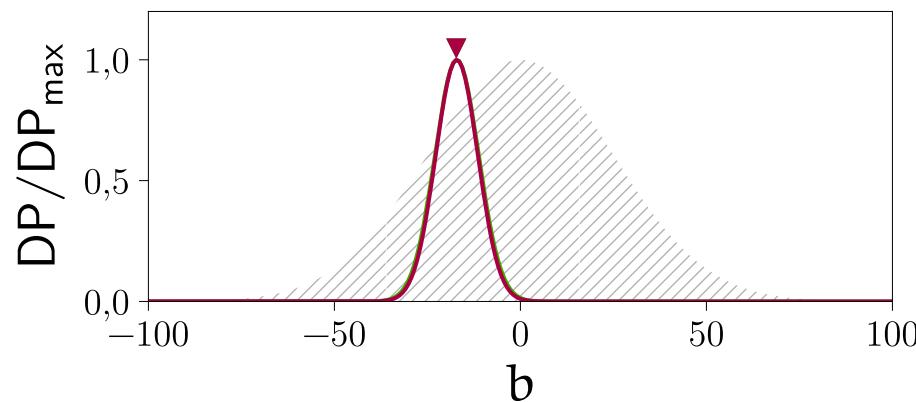
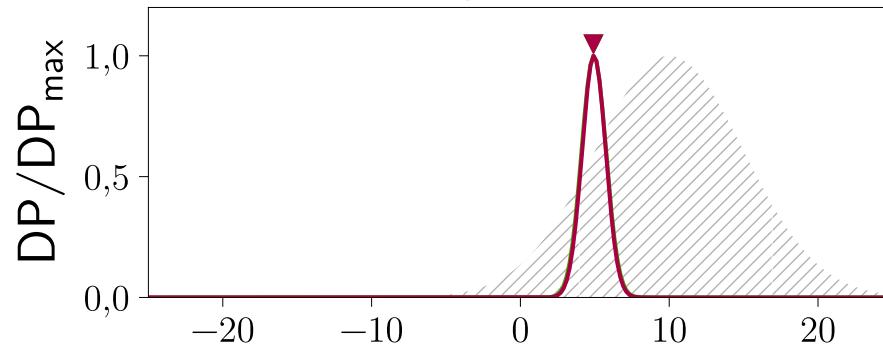
Distribución Posterior

Función de Verosimilitud

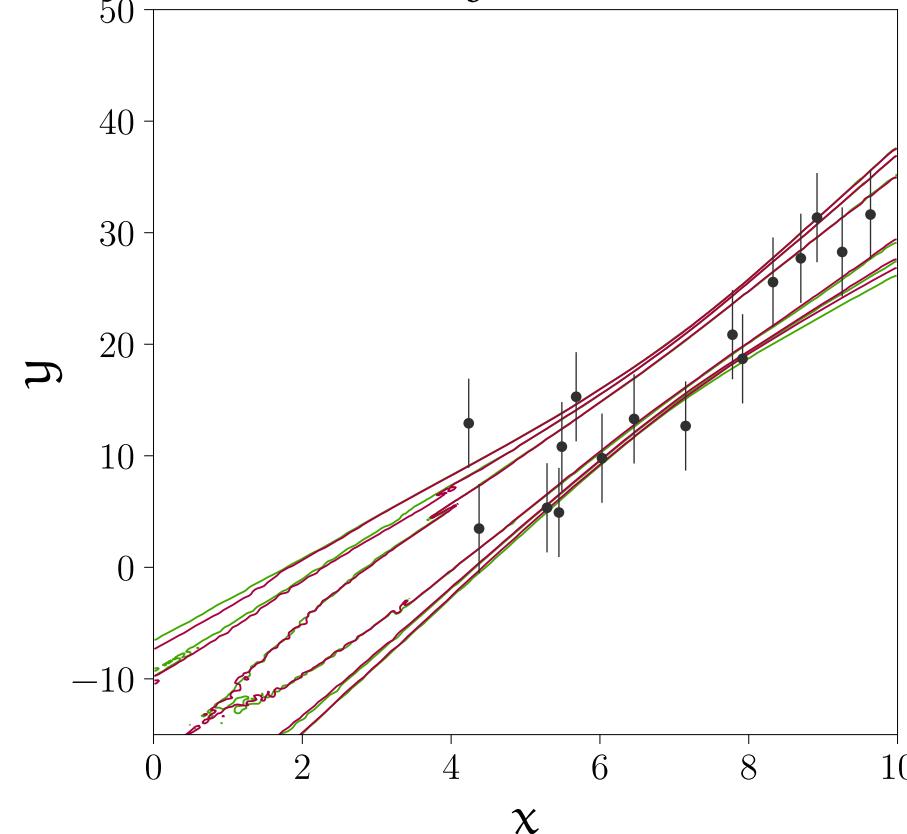
Distribución Previa

# EL ROL DE LA DISTRIBUCIÓN PREVIA – SEÑAL/RUIDO DE LAS OBSERVACIONES

$$\sigma_y = 4,0$$



$$\sigma_y = 4,0$$



*En el límite  $\sigma_y \rightarrow 0$   
la distribución previa  
se vuelve irrelevante.*

$$P(m, b | \{y\}, \{x\}, \{\sigma_y\}) \propto \mathcal{L}(m, b | \{y\}, \{x\}, \{\sigma_y\}) \times P(m, b | \{x\}, \{\sigma_y\})$$

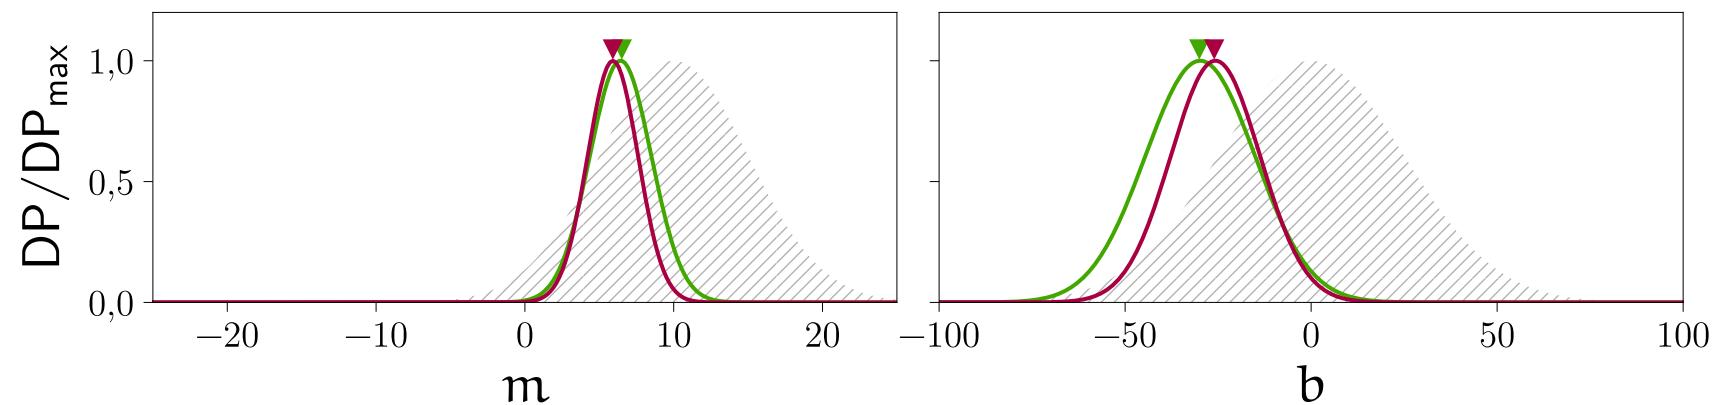
Distribución Posterior

Función de Verosimilitud

Distribución Previa

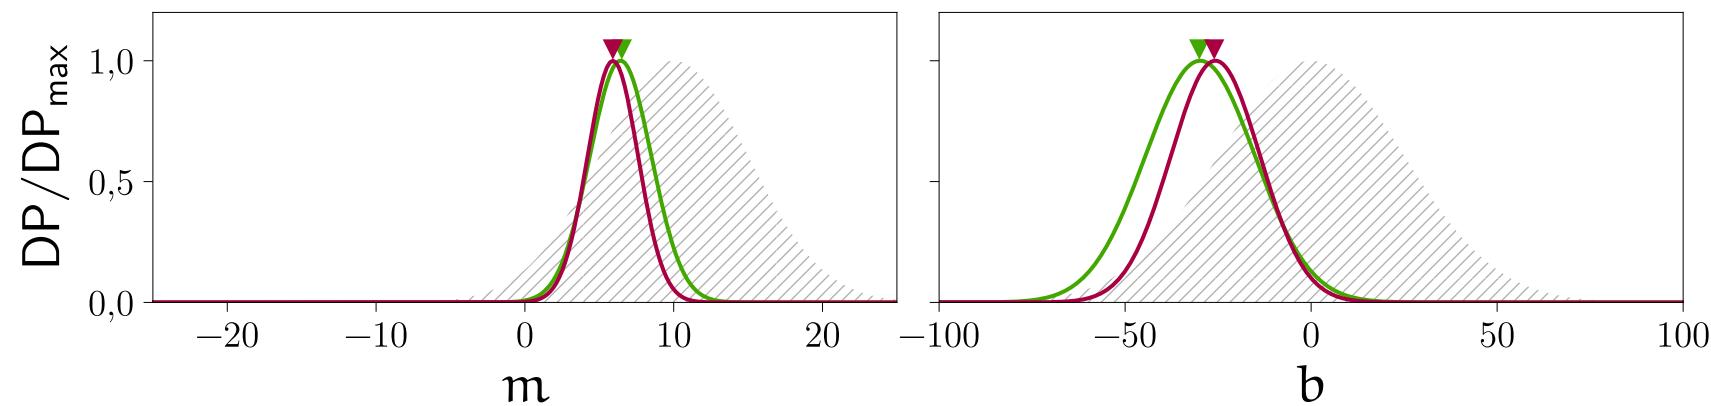
# RESUMEN – EL ROL DE LA DISTRIBUCIÓN PREVIA

- Proporcionar un punto de partida en el espacio de Hipótesis.
- Facilitar el muestreo de la Verosimilitud.
- En el límite de observaciones informativas, la Distribución Previa debe ser irrelevante.
- Aún así, la Distribución Previa debe ser independiente de las observaciones.



# RESUMEN – EL ROL DE LA DISTRIBUCIÓN PREVIA

- Proporcionar un punto de partida en el espacio de Hipótesis.
- Facilitar el muestreo de la Verosimilitud.
- En el límite de observaciones informativas, la Distribución Previa debe ser irrelevante.
- Aún así, la Distribución Previa debe ser independiente de las observaciones.



*¿Cómo asignar la Distribución Previa de manera honesta?*

# ¿CÓMO ASIGNAR LA DISTRIBUCIÓN PREVIA?

$$\mathcal{L}(\mathcal{H} | \mathcal{D}, \mathcal{C}), \textcolor{orange}{P}(\mathcal{H} | \mathcal{C}) \xrightarrow{\cdot ?} \text{Información}$$

# ¿CÓMO ASIGNAR LA DISTRIBUCIÓN PREVIA?

$$\mathcal{L}(\mathcal{H} | \mathcal{D}, \mathcal{C}), \textcolor{orange}{P}(\mathcal{H} | \mathcal{C}) \xrightarrow{?} \text{Información}$$



$$P(N | C)$$

Probabilidad de nubes  
sobre Sta. Rosa

# ¿CÓMO ASIGNAR LA DISTRIBUCIÓN PREVIA?

$$\mathcal{L}(\mathcal{H} | \mathcal{D}, \mathcal{C}), \textcolor{orange}{P}(\mathcal{H} | \mathcal{C}) \xrightarrow{?} \text{Información}$$



$$P(N | C)$$

Probabilidad de nubes  
sobre Sta. Rosa

$$I(P) \rightarrow 0$$

# ¿CÓMO ASIGNAR LA DISTRIBUCIÓN PREVIA?

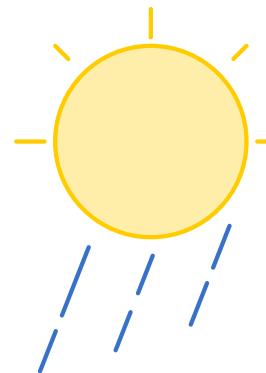
$$\mathcal{L}(\mathcal{H} | \mathcal{D}, \mathcal{C}), \textcolor{orange}{P}(\mathcal{H} | \mathcal{C}) \xrightarrow{?} \text{Información}$$



$$P(N | C)$$

Probabilidad de nubes  
sobre Sta. Rosa

$$I(P) \rightarrow 0$$



$$P(L, \bar{N} | C)$$

Probabilidad de lluvia  
con cielo despejado

# ¿CÓMO ASIGNAR LA DISTRIBUCIÓN PREVIA?

$$\mathcal{L}(\mathcal{H} | \mathcal{D}, \mathcal{C}), \textcolor{orange}{P}(\mathcal{H} | \mathcal{C}) \xrightarrow{?} \text{Información}$$



$$P(N | C)$$

Probabilidad de nubes  
sobre Sta. Rosa

$$I(P) \rightarrow 0$$



$$P(L, \bar{N} | C)$$

Probabilidad de lluvia  
con cielo despejado

$$I(P) \rightarrow \infty$$

# **¿CÓMO ASIGNAR LA DISTRIBUCIÓN PREVIA?**

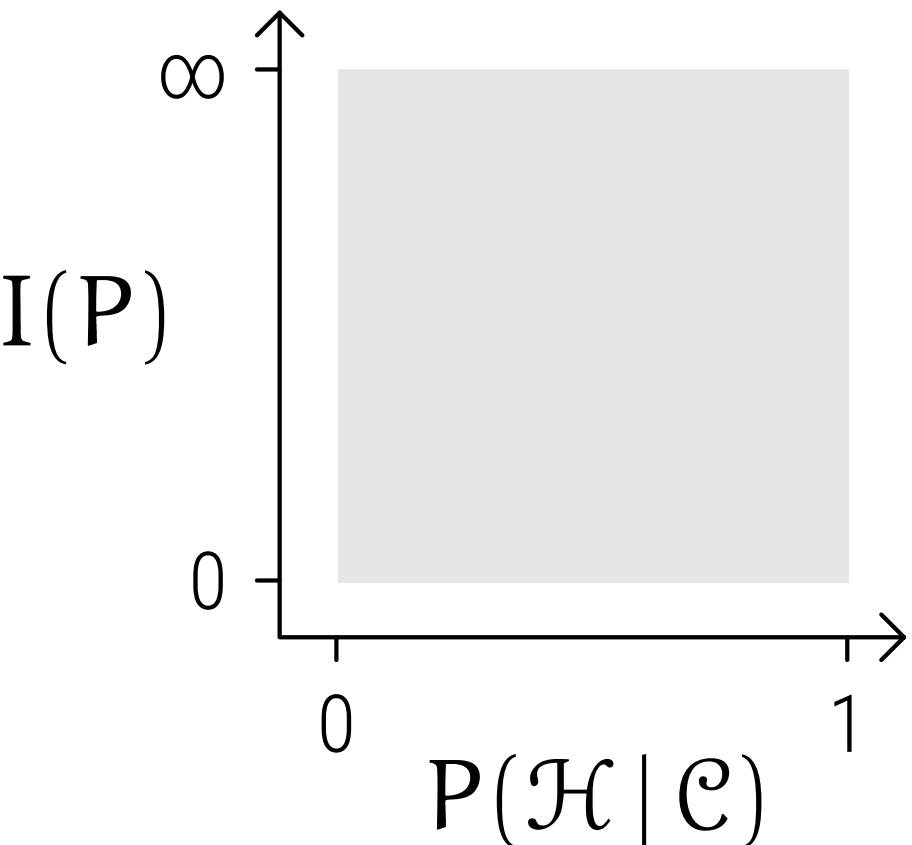
INFORMACIÓN: medida de la impredecibilidad en la ocurrencia de un evento.

# ¿CÓMO ASIGNAR LA DISTRIBUCIÓN PREVIA?

INFORMACIÓN: medida de la impredecibilidad en la ocurrencia de un evento.

REGLAS DE SHANNON:

$$I : I(P)$$



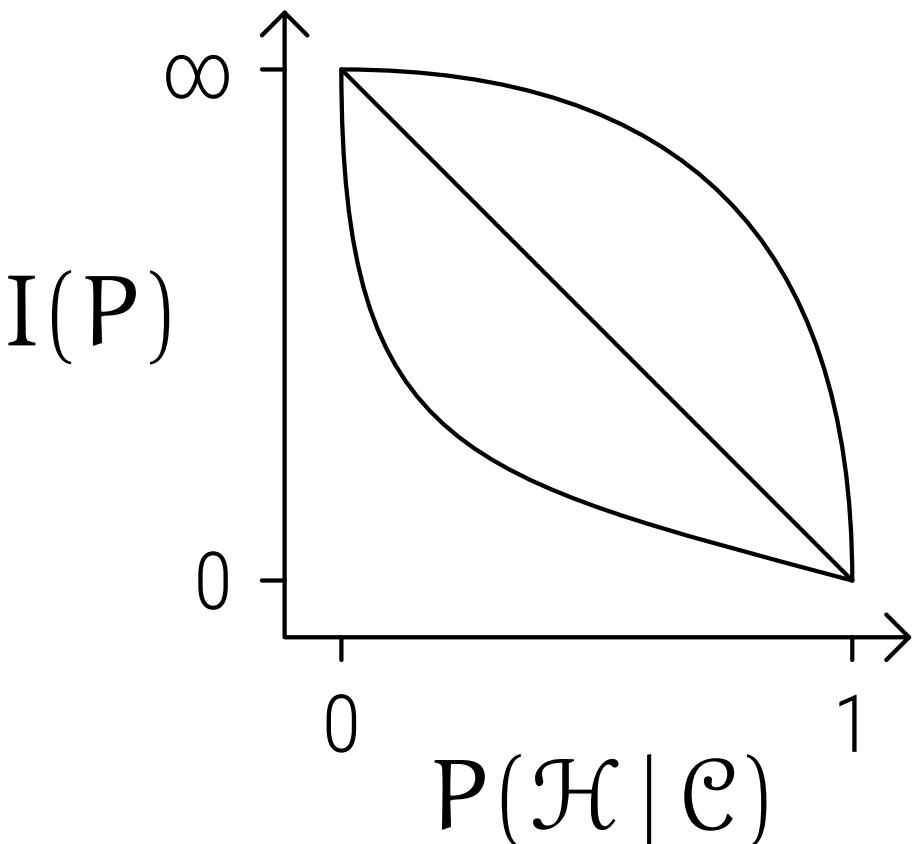
# ¿CÓMO ASIGNAR LA DISTRIBUCIÓN PREVIA?

INFORMACIÓN: medida de la impredecibilidad en la ocurrencia de un evento.

REGLAS DE SHANNON:

$$I : I(P)$$

$I(P)$  es monótona y continua



# ¿CÓMO ASIGNAR LA DISTRIBUCIÓN PREVIA?

INFORMACIÓN: medida de la impredecibilidad en la ocurrencia de un evento.

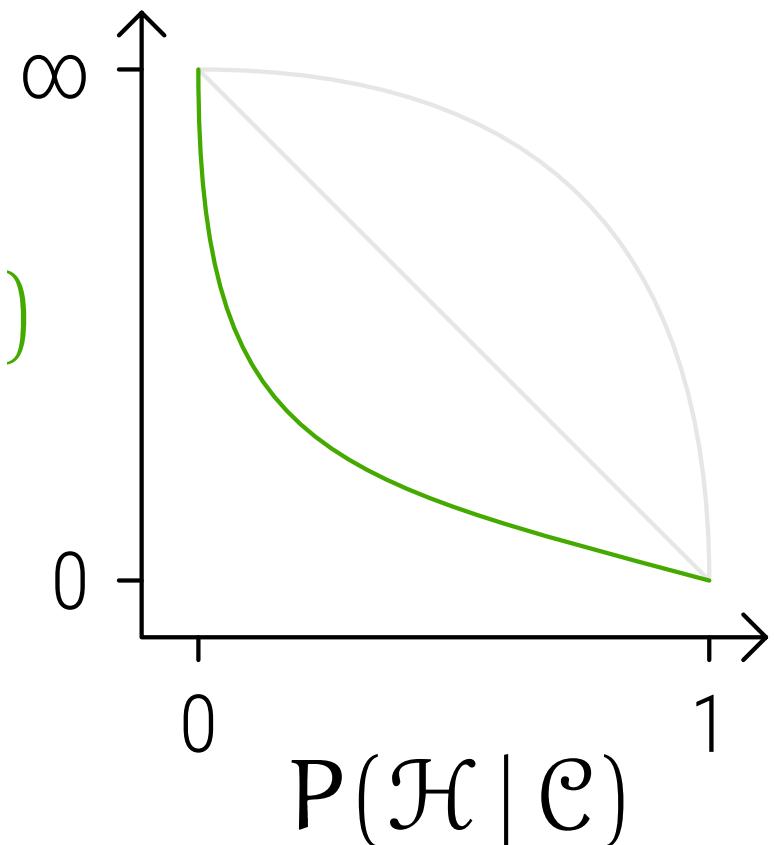
$$-\log P \equiv I(P)$$

REGLAS DE SHANNON:

$$I : I(P)$$

$I(P)$  es monótona y continua

$$I(P_A \times P_B) = I(P_A) + I(P_B)$$



# ¿CÓMO ASIGNAR LA DISTRIBUCIÓN PREVIA?

INFORMACIÓN: medida de la impredictibilidad en la ocurrencia de un evento.

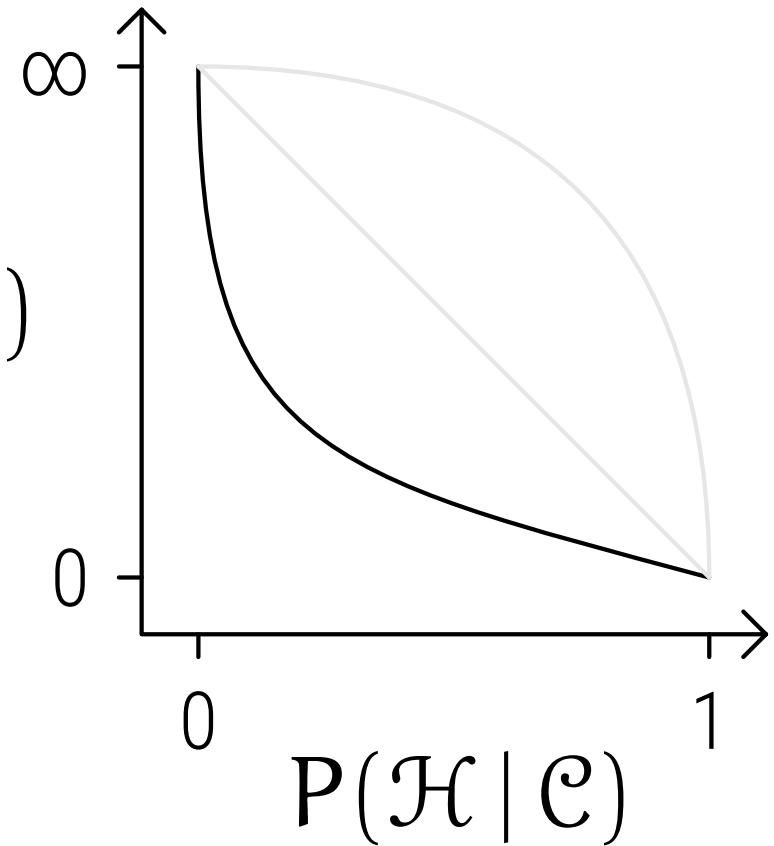
$$-\log P \equiv I(P)$$

REGLAS DE SHANNON:

$$I : I(P)$$

$I(P)$  es monótona y continua

$$I(P_A \times P_B) = I(P_A) + I(P_B)$$



$P(\mathcal{H} | \mathcal{C})$

Distribución Previa

- Muda respecto de  $\mathcal{L}(\mathcal{H} | \mathcal{D}, \mathcal{C})$
- Informativa únicamente a través de  $\mathcal{C}$

# ¿CÓMO ASIGNAR LA DISTRIBUCIÓN PREVIA?: MÉTODO DE MÁXIMA ENTROPÍA

$$L(P, P'; \mathcal{H}) \equiv \int_{\mathcal{H}} P(\mathcal{H} | \mathcal{C}) \times \log 1/P(\mathcal{H} | \mathcal{C})$$

Información esperada  
ó Entropía,  $H(P)$

*Distribución de  
Probabilidad a priori*

Información adquirida  
tras la observación

# ¿CÓMO ASIGNAR LA DISTRIBUCIÓN PREVIA?: MÉTODO DE MÁXIMA ENTROPÍA

$$L(P, P'; \mathcal{H}) \equiv \int_{\mathcal{H}} P(\mathcal{H} | \mathcal{C}) \times \log 1/P(\mathcal{H} | \mathcal{C}) ; \quad \sum_{i=0} \lambda_i g_i(P, P'; \mathcal{H})$$

Información esperada ó Entropía,  $H(P)$

*Distribución de Probabilidad a priori*

Información adquirida tras la observación

Restricciones impuestas por la información contrastable

# ¿CÓMO ASIGNAR LA DISTRIBUCIÓN PREVIA?: MÉTODO DE MÁXIMA ENTROPÍA

$$L(P, P'; \mathcal{H}) \equiv \int_{\mathcal{H}} P(\mathcal{H} | \mathcal{C}) \times \log 1/P(\mathcal{H} | \mathcal{C}) ; \quad \sum_{i=0} \lambda_i g_i(P, P'; \mathcal{H})$$

Las restricciones fijan propiedades macro

La información verificable define el conjunto de restricciones

Información esperada ó Entropía,  $H(P)$

Distribución de Probabilidad a priori

Información adquirida tras la observación

Restricciones impuestas por la información contrastable

# ¿CÓMO ASIGNAR LA DISTRIBUCIÓN PREVIA?: MÉTODO DE MÁXIMA ENTROPÍA

$$L(P, P'; \mathcal{H}) \equiv \int_{\mathcal{H}} P(\mathcal{H} | \mathcal{C}) \times \log 1/P(\mathcal{H} | \mathcal{C}) ; \sum_{i=0} \lambda_i g_i(P, P'; \mathcal{H})$$

Las restricciones fijan propiedades macro

La información verificable define el conjunto de restricciones

Información esperada ó Entropía,  $H(P)$

Distribución de Probabilidad a priori

Información adquirida tras la observación

Restricciones impuestas por la información contrastable

$$\max H : \frac{\partial L}{\partial P} - \frac{d}{d\mathcal{H}} \frac{\partial L}{\partial P'} + \sum_i \lambda_i \frac{\partial g_i}{\partial P} = 0$$

Ecuación de Euler-Lagrange

# ¿CÓMO ASIGNAR LA DISTRIBUCIÓN PREVIA?: MÉTODO DE MÁXIMA ENTROPÍA

$$L(P, P'; \mathcal{H}) \equiv \int_{\mathcal{H}} P(\mathcal{H} | \mathcal{C}) \times \log 1/P(\mathcal{H} | \mathcal{C}) ; \quad \sum_{i=0} \lambda_i g_i(P, P'; \mathcal{H})$$

Las restricciones fijan propiedades macro

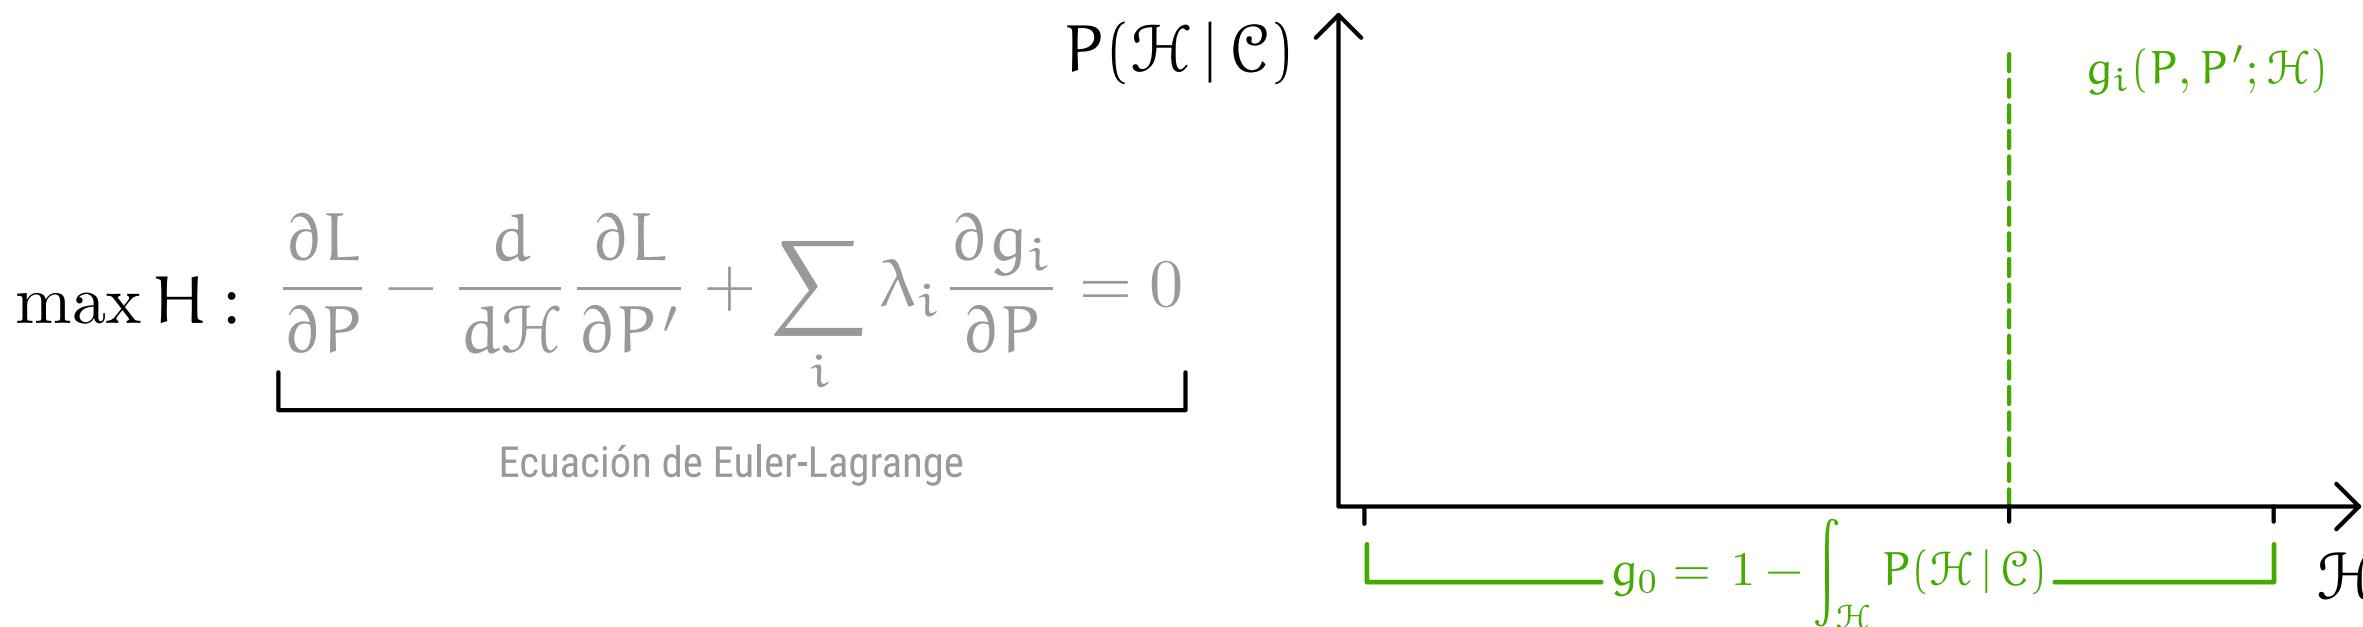
La información verificable define el conjunto de restricciones

Información esperada  
ó Entropía,  $H(P)$

Distribución de  
Probabilidad a priori

Información adquirida  
tras la observación

Restricciones impuestas por la  
información contrastable



# ¿CÓMO ASIGNAR LA DISTRIBUCIÓN PREVIA?: MÉTODO DE MÁXIMA ENTROPÍA

$$L(P, P'; \mathcal{H}) \equiv \int_{\mathcal{H}} P(\mathcal{H} | \mathcal{C}) \times \log 1/P(\mathcal{H} | \mathcal{C}) ; \quad \sum_{i=0} \lambda_i g_i(P, P'; \mathcal{H})$$

Las restricciones fijan propiedades macro  
 La información verificable define el conjunto de restricciones

Información esperada ó Entropía,  $H(P)$

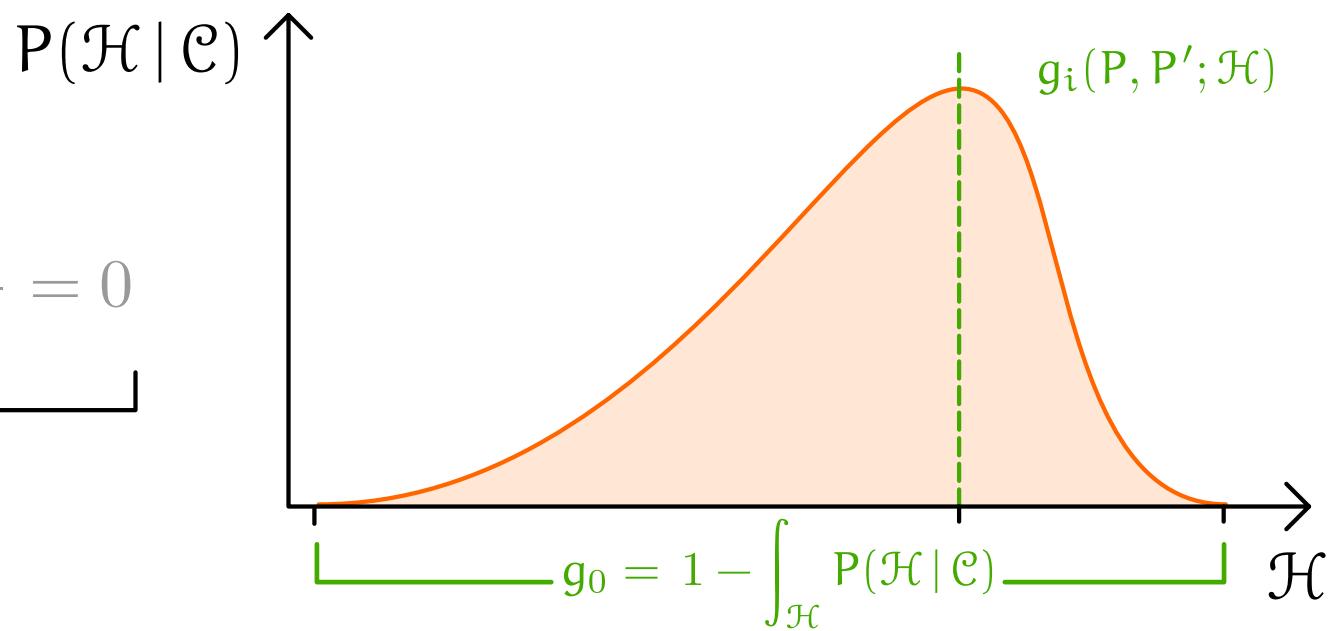
Distribución de Probabilidad a priori

Información adquirida tras la observación

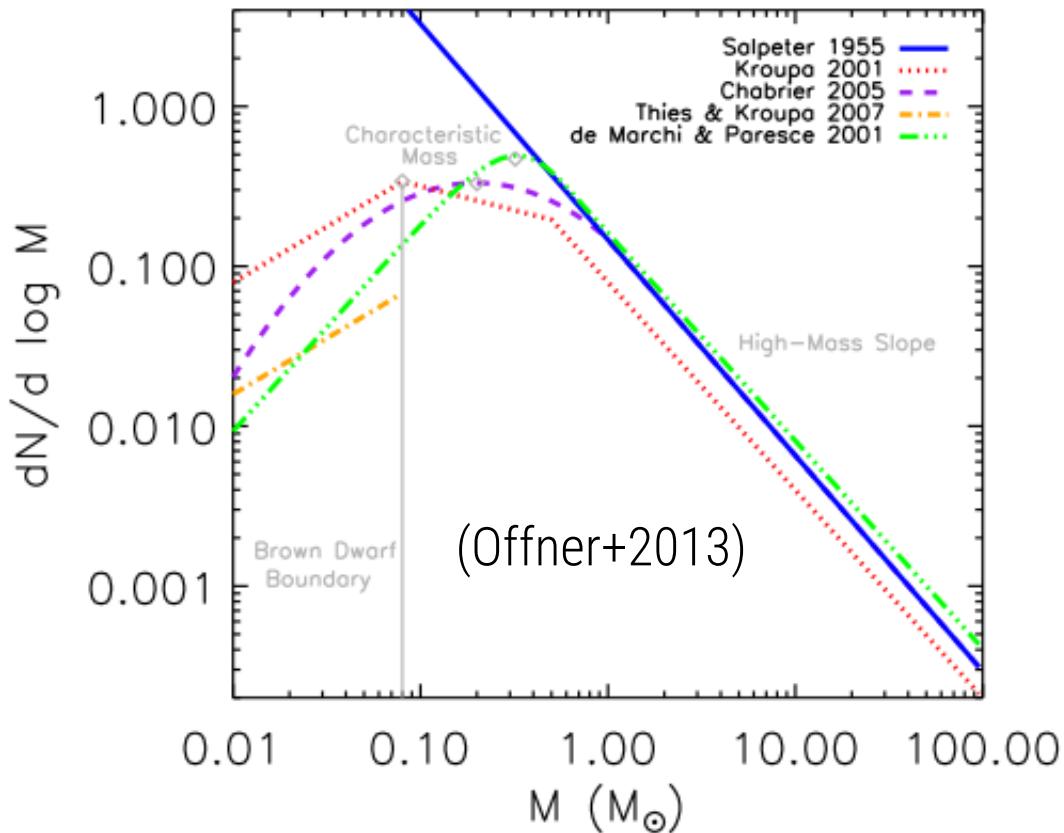
Restricciones impuestas por la información contrastable

$$\max H : \frac{\partial L}{\partial P} - \frac{d}{d\mathcal{H}} \frac{\partial L}{\partial P'} + \sum_i \lambda_i \frac{\partial g_i}{\partial P} = 0$$

Ecuación de Euler-Lagrange



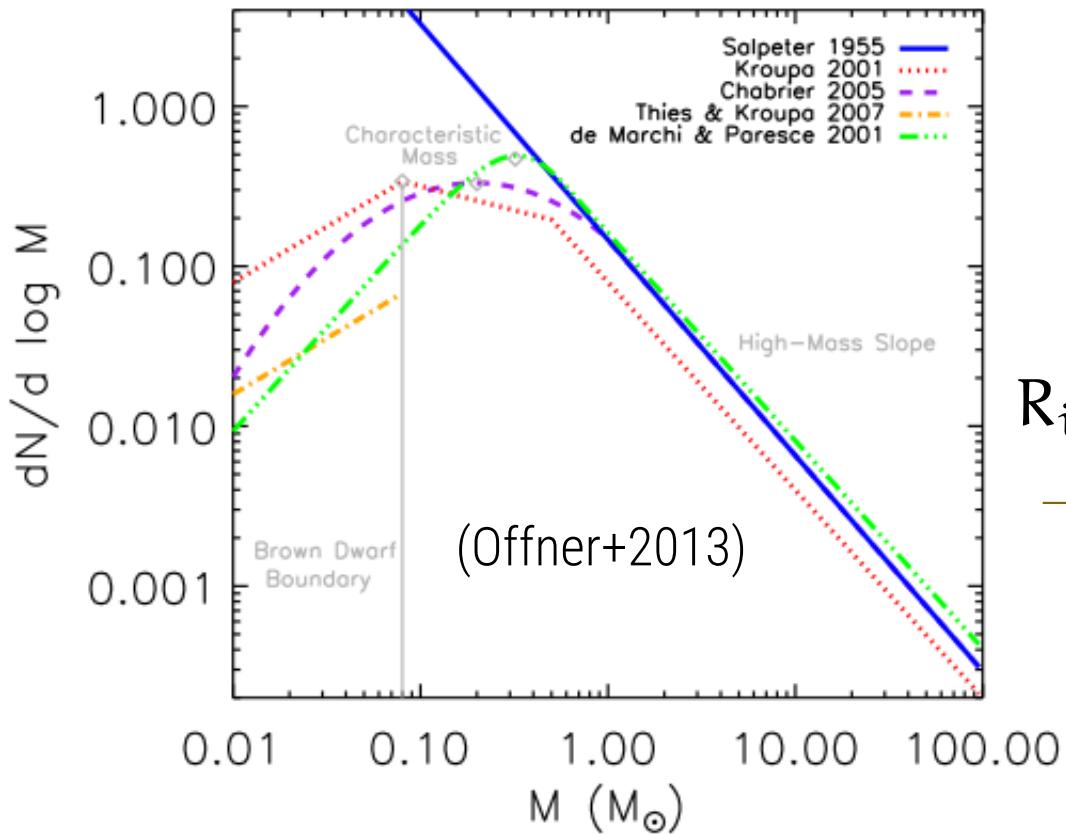
# MÉTODO DE MÁXIMA ENTROPIA – FUNCIÓN INICIAL DE MASA



$$P(m | \mathcal{C}) = \gamma m^{-\alpha}$$

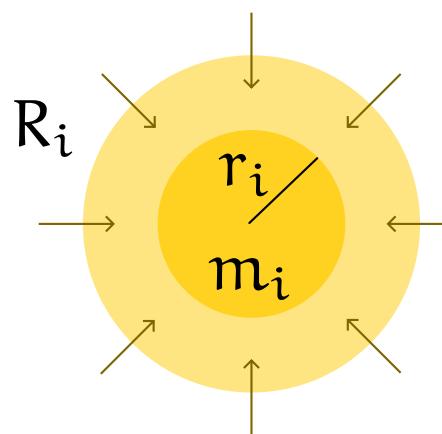
Vamos a recuperar la FIM de Salpeter usando simples suposiciones físicas y el método de Máxima Entropía.

# MÉTODO DE MÁXIMA ENTROPIA – FUNCIÓN INICIAL DE MASA



$$P(m | \mathcal{C}) = \gamma m^{-\alpha}$$

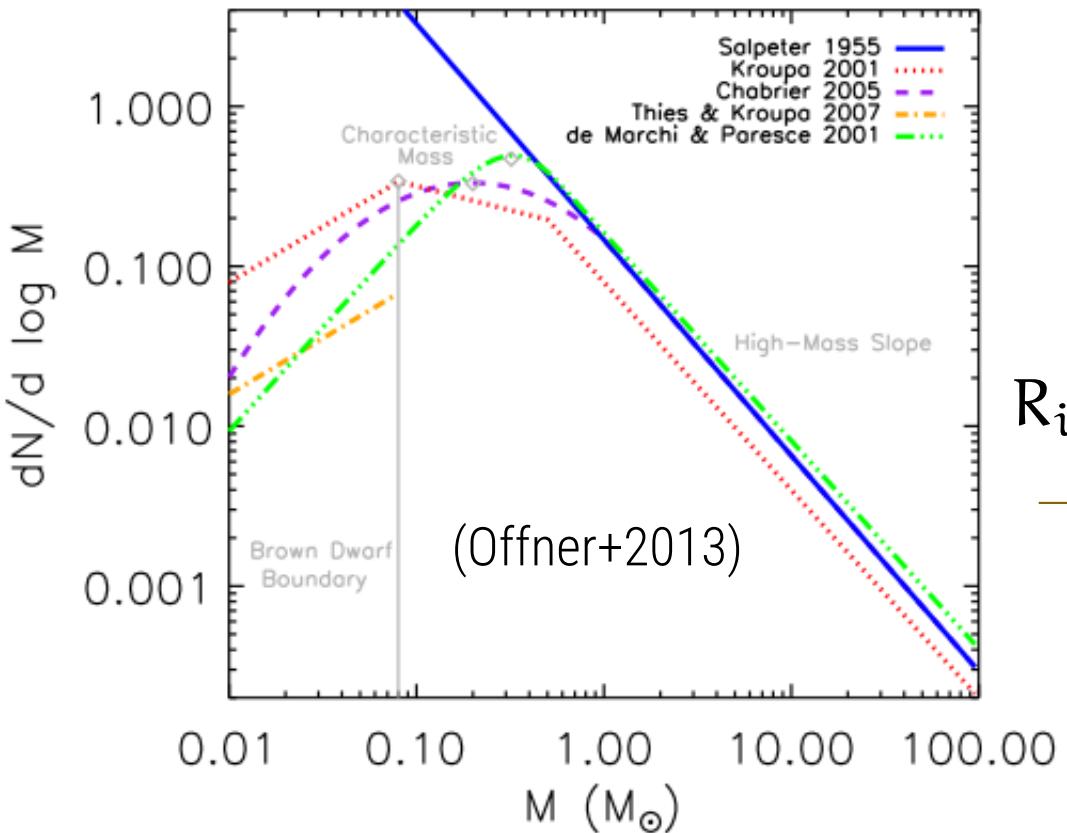
Vamos a recuperar la FIM de Salpeter usando simples suposiciones físicas y el método de Máxima Entropía.



$$R_i = \frac{m_i}{\tau_i^{\text{din}}}$$

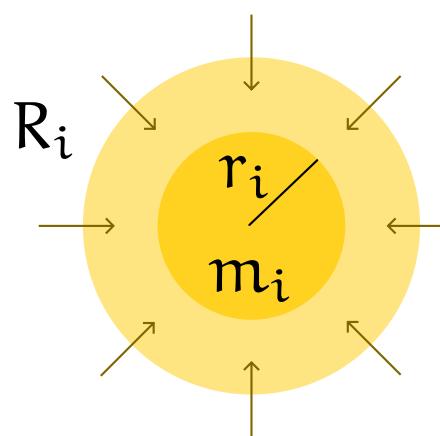
$$\tau^{\text{din}} \propto 1/\rho_i^{1/2}$$

# MÉTODO DE MÁXIMA ENTROPIA – FUNCIÓN INICIAL DE MASA



$$P(m | \mathcal{C}) = \gamma m^{-\alpha}$$

Vamos a recuperar la FIM de Salpeter usando simples suposiciones físicas y el método de Máxima Entropía.



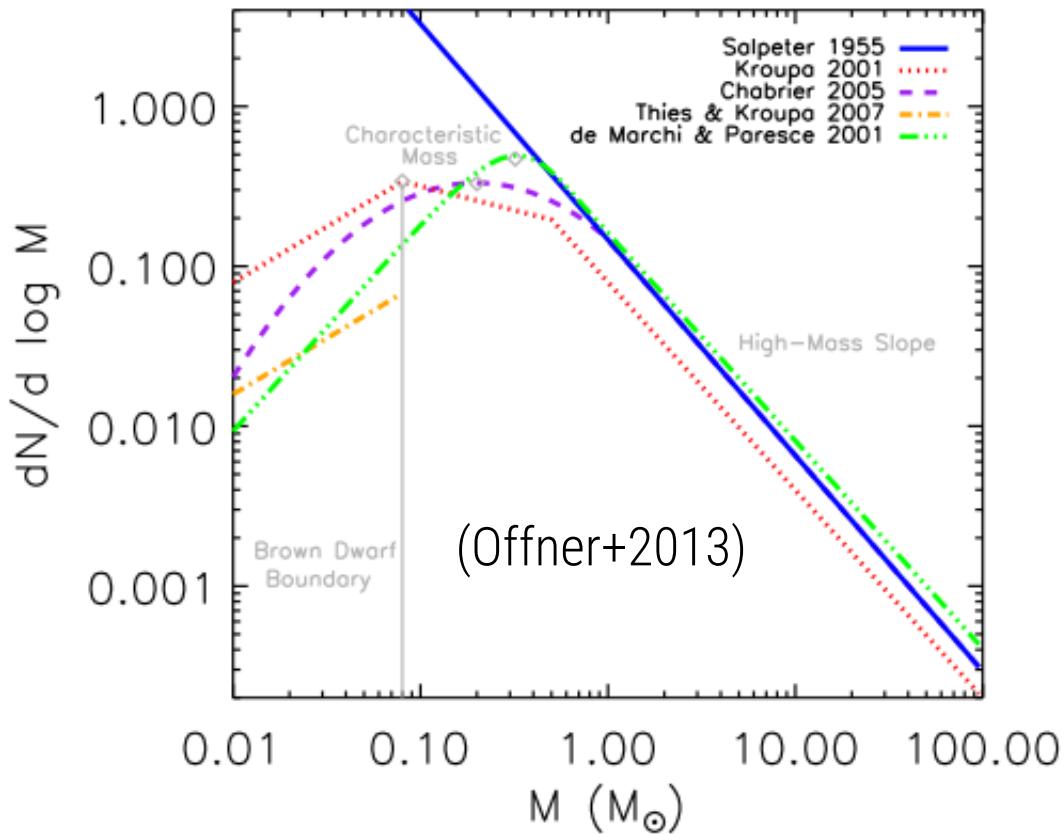
$$R_i = \frac{m_i}{\tau_i^{\text{din}}}$$

$$\tau^{\text{din}} \propto 1/\rho_i^{1/2}$$

$$R_i \propto (m_i r_i)^{3/2} \implies \rho_{R,i} \equiv R_i/V_i \propto (m_i/r_i)^{3/2}$$

Queremos hallar el conjunto de  $\{P_i\}$  tal que represente la DP de que una estrella haya alcanzado una masa  $m_i$  en la Secuencia Principal ( $R_i = 0$ ).

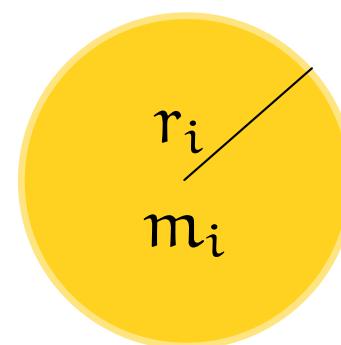
# MÉTODO DE MÁXIMA ENTROPIA – FUNCIÓN INICIAL DE MASA



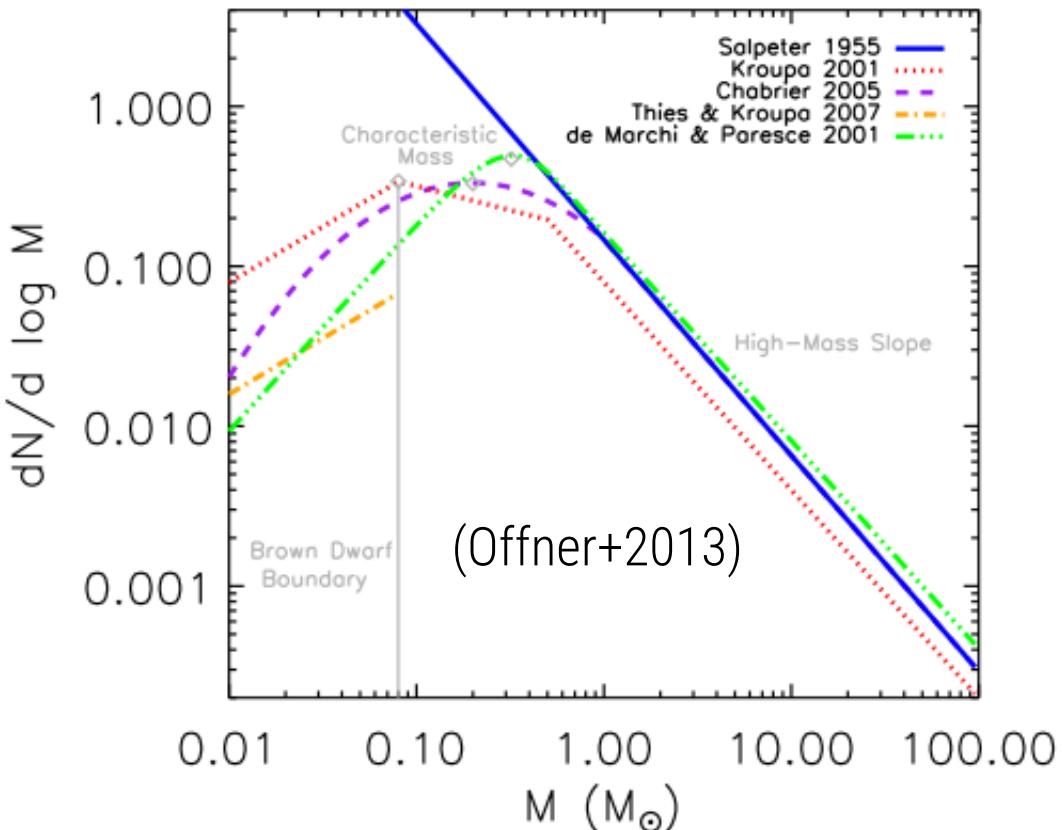
$$P(m | \mathcal{C}) = \gamma m^{-\alpha}$$

Vamos a recuperar la FIM de Salpeter usando simples suposiciones físicas y el método de Máxima Entropía.

$$R_i = 0 \implies r_i = m_i^{4/5}$$



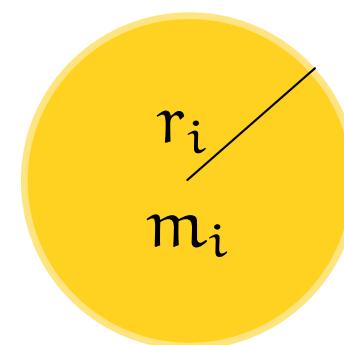
# MÉTODO DE MÁXIMA ENTROPIA – FUNCIÓN INICIAL DE MASA



$$P(m | \mathcal{C}) = \gamma m^{-\alpha}$$

Vamos a recuperar la FIM de Salpeter usando simples suposiciones físicas y el método de Máxima Entropía.

$$R_i = 0 \implies r_i = m_i^{4/5}$$



$$\rho_{R,i} = m_i^{1/5}$$

Vamos a suponer que la densidad de Tasa de Acreción es una versión local de la Ley de Kennicutt-Schmidt:

$$\rho_{\text{TFE}} \propto \rho_{\text{gas}}^{3/2}$$

$\implies$

$$\sum_i P_i \log m_i \propto \log \rho_{\text{gas}} + \text{const}$$

## MÉTODO DE MÁXIMA ENTROPÍA – FUNCIÓN INICIAL DE MASA

$$L(P_i, P'_i, m_i) = \sum_i P_i \log 1/P_i$$

Lagrangiano: Entropía

# MÉTODO DE MÁXIMA ENTROPIA – FUNCIÓN INICIAL DE MASA

$$L(P_i, P'_i, m_i) = \sum_i P_i \log 1/P_i$$

Lagrangiano: Entropía

$$g_0 = \sum_i P_i - 1$$

$$g_1 = \sum_i P_i \log m_i - \log \rho_{\text{gas}}$$

Restricciones  
basadas en la  
información  
contrastable

# MÉTODO DE MÁXIMA ENTROPIA – FUNCIÓN INICIAL DE MASA

$$L(P_i, P'_i, m_i) = \sum_i P_i \log 1/P_i$$

Lagrangiano: Entropía

$$\left. \begin{aligned} g_0 &= \sum_i P_i - 1 \\ g_1 &= \sum_i P_i \log m_i - \log \rho_{\text{gas}} \end{aligned} \right]$$

Restricciones  
basadas en la  
información  
contrastable

$$\frac{\partial L}{\partial P_i} - \frac{d}{dm_i} \frac{\partial L}{\partial P_i} + \sum_j \lambda_j \frac{\partial g_j}{\partial P_i} = -\log P_i - 1 + \lambda_0 + \lambda_1 \log m_i = 0$$

Ecuación de Euler-Lagrange

◻      ◻

$\log \gamma$        $-\alpha$

# MÉTODO DE MÁXIMA ENTROPIA – FUNCIÓN INICIAL DE MASA

$$L(P_i, P'_i, m_i) = \sum_i P_i \log 1/P_i$$

Lagrangiano: Entropía

$$\left. \begin{aligned} g_0 &= \sum_i P_i - 1 \\ g_1 &= \sum_i P_i \log m_i - \log \rho_{\text{gas}} \end{aligned} \right]$$

Restricciones  
basadas en la  
información  
contrastable

$$\frac{\partial L}{\partial P_i} - \frac{d}{dm_i} \frac{\partial L}{\partial P_i} + \sum_j \lambda_j \frac{\partial g_j}{\partial P_i} = -\log P_i - 1 + \lambda_0 + \lambda_1 \log m_i = 0$$

Ecuación de Euler-Lagrange

◻      ◻

$\log \gamma$        $-\alpha$

$$P_i = \gamma m_i^{-\alpha} \Rightarrow P(m | \mathcal{C}) = \gamma m^{-\alpha}$$

# MÉTODO DE MÁXIMA ENTROPIA – FUNCIÓN INICIAL DE MASA

$$L(P_i, P'_i, m_i) = \sum_i P_i \log 1/P_i$$

Lagrangiano: Entropía

$$\left. \begin{aligned} g_0 &= \sum_i P_i - 1 \\ g_1 &= \sum_i P_i \log m_i - \log \rho_{\text{gas}} \end{aligned} \right]$$

Restricciones basadas en la información contrastable

$$\frac{\partial L}{\partial P_i} - \frac{d}{dm_i} \frac{\partial L}{\partial P_i} + \sum_j \lambda_j \frac{\partial g_j}{\partial P_i} = -\log P_i - 1 + \lambda_0 + \lambda_1 \log m_i = 0$$

Ecuación de Euler-Lagrange

$$\boxed{\log \gamma} \quad \boxed{-\alpha}$$

$$P_i = \gamma m_i^{-\alpha} \Rightarrow P(m | \mathcal{C}) = \gamma m^{-\alpha}$$

¡Hemos encontrado una explicación estocástica para la FIM, usando relaciones de escala de la Astrofísica y el método de Máxima Entropía!

# RESUMEN

- La Distribución Previa debe asignarse de manera equilibrada.
- El método de Máxima Entropía proporciona la forma ideal de hacerlo.
- La Distribución Previa representa la mejor herramienta para muestrear la Verosimilitud.
- Sin embargo, la Inferencia Bayesiana presenta varias desventajas:

Es computacionalmente costosa.

No informa sobre qué tan bueno es el modelo propuesto.